

Projet Bloc IA

Analyse du turnover chez HumanForYou

Maxence Chartier

Amine Haouri

Anisse Imerzoukene

Mourad Messaoudi

30 mars 2026

Table des matières

1	Introduction	3
1.1	Contexte historique : des dérives aux législations	3
1.1.1	Tout commence par les fichiers : la naissance de la méfiance (années 1970)	3
1.1.2	La surveillance à l'ère numérique : quand les États dépassent les bornes (2001–2013)	3
1.1.3	L'ère du <i>big data</i> : quand les entreprises exploitent sans limites (2016–2018)	4
1.1.4	L'IA qui discrimine : le choc des biais algorithmiques (2016–2018)	4
1.1.5	La surveillance au travail et la prédiction comportementale : des dérives proches de notre sujet	5
1.1.6	Le spectre du contrôle total : Clearview AI et le crédit social	5
1.1.7	Du constat à la régulation : la chronologie d'une prise de conscience . . .	6
1.2	Objectifs du projet	6
2	Cadre réglementaire et éthique	7
2.1	Cadre réglementaire européen	8
2.1.1	Le Règlement Général sur la Protection des Données (RGPD)	8
2.1.2	La loi européenne sur l'intelligence artificielle (AI Act)	8
2.1.3	Les sept principes éthiques pour une IA digne de confiance	9
2.1.4	Cadre français : contributions majeures	10
2.2	Contributions de la DARPA (États-Unis)	10
2.2.1	Programmes majeurs liés à l'IA	10
2.2.2	Influence sur l'éthique de l'IA	11
2.3	Définitions : éthique et équité en intelligence artificielle	11
2.3.1	L'éthique en intelligence artificielle	12
2.3.2	L'équité en intelligence artificielle	12
2.4	Décisions et règles adoptées pour le projet	14
2.4.1	Respect de l'autonomie humaine	14
2.4.2	Robustesse technique et sécurité	15
2.4.3	Confidentialité et gouvernance des données	16
2.4.4	Transparence	17
2.4.5	Diversité, non-discrimination et équité	18
2.4.6	Bien-être environnemental et sociétal	19
2.4.7	Responsabilité	20
2.5	Application au projet HumanForYou sous le cadre européen	21
3	Conclusion	22

1 Introduction

L'entreprise **HumanForYou**, acteur du secteur des ressources humaines basé en Inde, fait face à un taux de turnover préoccupant parmi ses employés. Dans un contexte où la rétention des talents constitue un enjeu stratégique majeur, la direction souhaite exploiter les données RH disponibles pour comprendre les facteurs de départ et anticiper les risques d'attrition.

Avant de présenter les objectifs du projet, il est essentiel de comprendre *pourquoi* l'utilisation de l'IA dans les ressources humaines est aujourd'hui encadrée par des législations strictes. Cette réglementation n'est pas née dans un vide : elle est le fruit d'une histoire jalonnée de dérives, de scandales et de prises de conscience progressives.

1.1 Contexte historique : des dérives aux législations

La réglementation qui encadre aujourd'hui l'intelligence artificielle et la protection des données n'est pas apparue spontanément. Elle est le produit d'une histoire de plus de cinquante ans, faite de projets ambitieux qui ont dérapé, de scandales qui ont choqué l'opinion, et de prises de conscience successives. Chaque étape a nourri la suivante, dessinant progressivement le cadre juridique dans lequel notre projet s'inscrit.

1.1.1 Tout commence par les fichiers : la naissance de la méfiance (années 1970)

L'histoire débute bien avant l'intelligence artificielle, à une époque où l'informatique commence tout juste à s'imposer dans les administrations. En 1974, la France découvre le projet **SAFARI** (Système Automatisé pour les Fichiers Administratifs et le Répertoire des Individus) : le gouvernement prévoit d'interconnecter l'ensemble des fichiers administratifs français — impôts, sécurité sociale, police, état civil — via le numéro de sécurité sociale. L'ambition est de « rationaliser » la gestion publique, mais le résultat serait un fichage complet de chaque citoyen.

Le journal *Le Monde* titre « SAFARI ou la chasse aux Français » [8], et l'indignation est immédiate. Ce scandale conduit directement à l'adoption de la **loi Informatique et Libertés** du 6 janvier 1978 [7] et à la création de la **CNIL** — l'une des premières autorités de protection des données au monde. Le message est clair : même avec de bonnes intentions, le croisement massif de données personnelles représente une menace pour les libertés individuelles.

Ce premier avertissement pose un principe qui traversera les décennies suivantes : *ce n'est pas parce qu'on peut collecter et croiser des données qu'on doit le faire.*

1.1.2 La surveillance à l'ère numérique : quand les États dépassent les bornes (2001–2013)

Trente ans plus tard, la même question resurgit à une tout autre échelle. Après les attentats du 11 septembre 2001, le Pentagone lance le programme **Total Information Awareness** (TIA), qui vise à croiser massivement les données personnelles — transactions bancaires, communications, déplacements — pour détecter les menaces terroristes avant qu'elles ne se concrétisent. Le programme est officiellement abandonné en 2003 face à la pression du Congrès américain, qui y voit les prémices d'un État de surveillance.

Mais l'histoire ne s'arrête pas là. En 2013, Edward Snowden révèle que la NSA a poursuivi cette logique sous d'autres noms : **PRISM** permet d'accéder directement aux données des géants du numérique (Google, Facebook, Apple), tandis que **XKeyscore** permet de fouiller en temps réel les communications mondiales [13]. Ces révélations provoquent un séisme politique, en particulier en Europe, où l'on découvre que les données des citoyens européens sont aspirées sans aucun garde-fou.

C'est cette prise de conscience qui accélère l'adoption du **RGD** par le Parlement européen en 2016 [1] : l'Europe décide qu'il est temps de reprendre le contrôle sur les données de ses citoyens, non seulement face aux États, mais aussi face aux entreprises privées qui accumulent des volumes de données sans précédent. Le RGD entre en application le 25 mai 2018, imposant pour la première fois des sanctions réellement dissuasives (jusqu'à 4 % du chiffre d'affaires mondial).

1.1.3 L'ère du *big data* : quand les entreprises exploitent sans limites (2016–2018)

Mais à peine le RGD est-il entré en vigueur qu'un scandale vient démontrer l'ampleur du problème. En mars 2018, le *New York Times* et *The Guardian* révèlent l'affaire **Cambridge Analytica** [15] : la société britannique a exploité les données personnelles de **87 millions d'utilisateurs Facebook**, collectées via une application tierce apparemment anodine (un quiz de personnalité), pour construire des profils psychologiques et cibler des messages politiques personnalisés lors de la campagne présidentielle américaine de 2016 et du référendum sur le Brexit.

Le scandale ne réside pas seulement dans la collecte non consentie : il réside dans l'*usage*. Les données personnelles ne servent plus à vendre des publicités — elles deviennent une **arme de manipulation démocratique**. Facebook est condamné à une amende record de 5 milliards de dollars par la FTC, et l'affaire devient le symbole d'une ère où les données personnelles sont le nouveau pétrole — et où ceux qui les détiennent peuvent en abuser à grande échelle.

C'est dans ce climat que les législateurs européens commencent à comprendre que protéger les données ne suffit plus : il faut aussi encadrer les *algorithmes* qui les exploitent.

1.1.4 L'IA qui discrimine : le choc des biais algorithmiques (2016–2018)

Car au-delà de la collecte abusive, un problème plus insidieux émerge : les algorithmes d'IA, même bien intentionnés, peuvent **reproduire et amplifier les discriminations humaines**.

En 2016, le média d'investigation ProPublica publie une enquête retentissante sur **COMPAS** (*Correctional Offender Management Profiling for Alternative Sanctions*), un logiciel utilisé par des tribunaux américains pour évaluer le risque de récidive des accusés [16]. L'enquête révèle que le système **surestimait systématiquement le risque pour les accusés afro-américains** : ceux-ci avaient presque deux fois plus de chances d'être faussement étiquetés comme futurs criminels que les accusés blancs. Le modèle, entraîné sur des données historiques reflétant des décennies de discrimination systémique dans la justice américaine, avait appris à perpétuer ces biais.

Ce cas a provoqué un débat fondamental : peut-on confier des décisions qui affectent la vie des gens à des algorithmes opaques ? La chercheuse Alexandra Chouldechova a démontré en 2017 [17], en réponse directe à l'affaire COMPAS, un résultat mathématique troublant : **il est impossible de satisfaire simultanément toutes les définitions**

de l'équité algorithmique. Autrement dit, rendre un algorithme « juste » implique nécessairement un choix éthique explicite — il n'existe pas de neutralité technique.

Deux ans plus tard, le problème frappe directement le monde des ressources humaines. En 2018, Reuters révèle qu'**Amazon** avait développé un outil de recrutement basé sur l'IA qui **discriminait systématiquement les femmes** [19]. Entraîné sur dix ans de CV reçus — majoritairement masculins dans le secteur technologique — le modèle avait appris à pénaliser les CV contenant le mot « women's » (comme « women's chess club ») et à favoriser les formulations typiquement masculines. Amazon a abandonné le projet, mais le mal était fait : le cas est devenu l'exemple emblématique des **biais algorithmiques en RH**, et exactement le type de risque que notre projet de prédiction d'attrition doit anticiper.

1.1.5 La surveillance au travail et la prédiction comportementale : des dérives proches de notre sujet

Ces scandales n'ont pas touché que le recrutement. Dans le domaine même de la gestion des employés — le cœur de notre projet — plusieurs dérives ont fait surface et illustrent les dangers d'une IA mal encadrée.

En 2017, des enquêtes révèlent qu'**Uber** utilisait des algorithmes pour détecter les chauffeurs susceptibles de rejoindre un mouvement de grève ou de quitter la plateforme, et leur proposait des incitations ciblées (bonus, courses avantageuses) pour les en dissuader [21]. En d'autres termes, Uber faisait exactement ce que notre projet propose — de la prédiction d'attrition — mais l'utilisait à des fins de **manipulation** plutôt que d'amélioration des conditions de travail. La frontière entre aide à la décision et contrôle social est mince.

En 2019, l'entreprise **HireVue** proposait un outil d'entretien vidéo analysant les expressions faciales et le ton de voix des candidats pour prédire leur performance future. L'Electronic Privacy Information Center (EPIC) a déposé une plainte [22], arguant que le système était opaque et potentiellement discriminatoire. Sous la pression publique et réglementaire, HireVue a fini par abandonner l'analyse faciale en 2021.

Enfin, en 2020, la banque **Barclays** a été contrainte d'abandonner un logiciel de surveillance qui traquait le temps passé par chaque employé à son bureau, ses pauses et sa productivité en temps réel. L'affaire, révélée par la presse [23], a provoqué l'intervention de l'Information Commissioner's Office (ICO) britannique. Le message est clair : même dans un cadre professionnel, la surveillance algorithmique a des limites.

1.1.6 Le spectre du contrôle total : Clearview AI et le crédit social

Parallèlement à ces dérives sectorielles, deux cas ont cristallisé les craintes les plus profondes de la société civile.

La start-up américaine **Clearview AI** a constitué une base de données de plus de **3 milliards d'images faciales** en aspirant sans autorisation les photos publiées sur les réseaux sociaux. Cette base était vendue à des forces de l'ordre et des entreprises privées pour identifier n'importe quel individu à partir d'une simple photo. En 2022, la CNIL a infligé à Clearview une amende de **20 millions d'euros** [14], et l'entreprise a été sanctionnée dans plusieurs pays. Ce cas a montré que la collecte massive de données biométriques, sans consentement et sans finalité définie, pouvait transformer tout espace public en un dispositif de surveillance.

Mais c'est peut-être le **système de crédit social chinois**, déployé progressivement depuis 2014, qui incarne le mieux le scénario que les régulateurs européens cherchent à prévenir. Ce système agrège des données comportementales — paiements, infractions, activité en ligne, relations sociales — pour attribuer à chaque citoyen un score influençant son accès au crédit, aux transports, à l'emploi et aux services publics. L'AI Act européen cite explicitement ce type de système comme un **risque inacceptable** (article 5) : les systèmes de notation sociale y sont purement et simplement interdits.

1.1.7 Du constat à la régulation : la chronologie d'une prise de conscience

Chacun de ces scandales a laissé une trace dans le paysage législatif. Vue d'ensemble, la chronologie dessine une accélération :

1. **1978** : loi Informatique et Libertés en France, en réaction au projet SAFARI ;
2. **2016** : adoption du RGPD par le Parlement européen, catalysée par les révélations Snowden et la prise de conscience sur la valeur des données personnelles ;
3. **2019** : publication des lignes directrices éthiques du HLEG européen, en réponse aux scandales Cambridge Analytica et Amazon ;
4. **2021** : proposition de l'AI Act par la Commission européenne, motivée par les affaires COMPAS, Clearview AI et la crainte d'un « crédit social à l'européenne » ;
5. **2023** : adoption du DPDPA indien [24], dans un contexte de pression internationale et de scandales locaux liés à Aadhaar (fuites de données biométriques de plus d'un milliard de citoyens indiens) ;
6. **2024** : entrée en vigueur de l'AI Act, premier cadre juridique contraignant au monde spécifiquement dédié à l'intelligence artificielle.

La figure 1 offre une vue d'ensemble de cette progression, où chaque scandale a catalysé une avancée réglementaire.

C'est dans ce contexte historique que s'inscrit notre projet. L'utilisation de l'IA pour prédire l'attrition des employés touche directement aux enjeux soulevés par ces affaires : les biais algorithmiques d'Amazon montrent ce qui arrive quand un modèle RH apprend sur des données biaisées ; la surveillance de Barclays illustre la frontière entre analyse et contrôle ; la manipulation d'Uber rappelle qu'un même outil — la prédiction d'attrition — peut servir l'employé ou l'asservir, selon l'intention de celui qui le déploie. Comprendre cette histoire n'est pas un exercice académique : c'est une condition préalable pour concevoir un système **responsable, équitable et conforme**.

1.2 Objectifs du projet

Ce projet s'inscrit dans le cadre du bloc de formation en Intelligence Artificielle et poursuit plusieurs objectifs :

1. **Analyser le cadre réglementaire et éthique** entourant l'utilisation de l'IA appliquée aux données RH ;
2. **Explorer et préparer les données** issues de quatre sources distinctes (données générales, enquêtes, évaluations managériales, horaires de badgeage) ;
3. **Construire des modèles prédictifs** de l'attrition à l'aide de techniques de régression et de classification ;




FIGURE 1 – Chronologie des incidents et réponses réglementaires (1974–2024). Les flèches en pointillés illustrent les liens de causalité entre scandales et avancées législatives.

4. **Formuler des recommandations** concrètes et actionnables à destination de la direction de HumanForYou.

L'enjeu final n'est pas seulement de produire un modèle performant, mais de transformer les résultats en recommandations stratégiques compréhensibles par un décideur.

Bien que le jeu de données provienne d'une entreprise indienne, nous nous plaçons **dans le cadre réglementaire européen** (RGPD, AI Act) pour analyser les enjeux éthiques et juridiques, celui-ci constituant le cadre le plus exigeant et le plus complet à ce jour.

2 Cadre réglementaire et éthique

L'utilisation de l'intelligence artificielle dans le domaine des ressources humaines — notamment pour la prédiction de l'attrition des employés — soulève des questions éthiques et juridiques majeures. Nous nous plaçons ici dans le cadre européen, comme si le projet était déployé au sein de l'Union européenne.

2.1 Cadre réglementaire européen

2.1.1 Le Règlement Général sur la Protection des Données (RGPD)

Le RGPD, entré en vigueur le 25 mai 2018, constitue le socle de la protection des données personnelles dans l'Union européenne. Il s'applique à tout traitement de données personnelles, qu'elles soient numériques ou non [1, 2].

Principes fondamentaux

Le règlement repose sur plusieurs principes clés directement applicables à notre projet :

- **Licéité, loyauté et transparence** : tout traitement doit reposer sur une base juridique valide (consentement, exécution d'un contrat, intérêt légitime, etc.) ;
- **Limitation des finalités** : les données ne peuvent être traitées que pour des fins déterminées et légitimes ;
- **Minimisation des données** : seules les données strictement nécessaires doivent être collectées ;
- **Exactitude** : les données doivent être tenues à jour et exactes ;
- **Limitation de la conservation** : les données ne doivent pas être conservées au-delà de la durée nécessaire ;
- **Intégrité et confidentialité** : des mesures techniques et organisationnelles appropriées doivent garantir la sécurité des données [10].

Article 22 — Décision individuelle automatisée

L'article 22 du RGPD est particulièrement pertinent pour notre projet. Il interdit, en principe, les décisions fondées exclusivement sur un traitement automatisé produisant des effets juridiques ou significatifs sur une personne. Dans le contexte RH, cela signifie qu'un modèle de prédiction de l'attrition **ne peut pas**, à lui seul, fonder une décision de licenciement, de mutation ou de rétrogradation. Trois exceptions sont prévues :

1. La décision est nécessaire à l'exécution d'un contrat ;
2. Elle est autorisée par le droit avec des garanties appropriées ;
3. Elle repose sur le consentement explicite de la personne concernée.

Dans tous les cas, la personne doit pouvoir obtenir une intervention humaine, exprimer son point de vue et contester la décision.

2.1.2 La loi européenne sur l'intelligence artificielle (AI Act)

Le règlement (UE) 2024/1689, dit *AI Act*, est entré en vigueur le 1^{er} août 2024 avec une application progressive (exigences pour les systèmes à haut risque applicables au 2 août 2026). Il instaure une classification des systèmes d'IA selon leur niveau de risque [3].

Classification par risque

- **Risque inacceptable** : systèmes interdits (notation sociale, manipulation subliminale, etc.) ;
- **Risque élevé** : systèmes soumis à des obligations strictes ;
- **Risque limité** : obligations de transparence ;
- **Risque minimal** : libre utilisation.

La figure 2 illustre cette classification et situe notre projet dans la catégorie à haut risque.




FIGURE 2 – Classification des systèmes d’IA par niveau de risque selon l’AI Act [3].

Les systèmes IA en RH : risque élevé

L’annexe III de l’AI Act classe explicitement comme **à haut risque** les systèmes d’IA utilisés dans le domaine de l’emploi, notamment pour :

- Le recrutement et la sélection de candidats ;
- Les décisions de promotion et de résiliation ;
- L’évaluation des performances et du comportement ;
- Le suivi et l’allocation des tâches.

Un système de prédiction de l’attrition tel que le nôtre relève très probablement de cette catégorie dès lors que ses résultats peuvent influencer des décisions relatives à la gestion du personnel.

Obligations pour les systèmes à haut risque

1. **Système de gestion des risques** : identification et atténuation des risques de biais, de discrimination et d’erreurs ;
2. **Gouvernance des données** : données d’entraînement de haute qualité (exactitude, complétude, représentativité), test de biais obligatoire ;
3. **Documentation et transparence** : documentation technique complète, notices d’utilisation, information des personnes concernées ;
4. **Contrôle humain** : supervision humaine effective, capacité d’intervention et de correction, personnel formé ;
5. **Évaluation d’impact** : réalisation d’une analyse d’impact relative à la protection des données (AIPD) avant déploiement.

2.1.3 Les sept principes éthiques pour une IA digne de confiance

Le Groupe d’Experts de Haut Niveau sur l’IA (HLEG), nommé par la Commission européenne, a défini en 2019 sept principes éthiques non contraignants, rappelés dans le considérant 27 de l’AI Act [4, 3] :

1. **Intervention humaine et supervision** : l’IA comme outil au service de l’humain ;
2. **Robustesse technique et sécurité** : résilience face aux erreurs et aux tentatives de détournement ;

3. **Protection de la vie privée et gouvernance des données** : conformité aux règles de protection des données ;
4. **Transparence** : traçabilité, explicabilité, information claire des utilisateurs ;
5. **Diversité, non-discrimination et équité** : prévention des biais et des effets discriminatoires ;
6. **Bien-être sociétal et environnemental** : IA durable et au service de tous ;
7. **Responsabilité** : mécanismes de reddition de comptes.

2.1.4 Cadre français : contributions majeures

Rapport de la CNIL (2017)

La Commission Nationale de l’Informatique et des Libertés a publié en décembre 2017 un rapport intitulé « *Comment permettre à l’Homme de garder la main ?* », issu d’un débat public réunissant 3 000 participants. Ce rapport pose deux principes fondateurs [9] :

- **Loyauté** : les algorithmes doivent servir les intérêts des utilisateurs en tant que citoyens, et non seulement en tant que consommateurs ;
- **Vigilance et réflexivité** : questionnement régulier et méthodique des systèmes algorithmiques par tous les acteurs.

Il formule six recommandations opérationnelles : former à l’éthique, rendre les systèmes compréhensibles, concevoir au service de la liberté humaine, constituer une plateforme nationale d’audit, encourager la recherche éthique, et renforcer la fonction éthique en entreprise.

Rapport Villani (2018)

Le rapport « *Donner un sens à l’intelligence artificielle* », remis au Premier ministre par Cédric Villani en mars 2018, définit une stratégie nationale et européenne en IA couvrant six dimensions : politique économique des données, recherche, emploi et transformation du travail, enjeux écologiques, cadre éthique, et inclusivité [11].

2.2 Contributions de la DARPA (États-Unis)

La *Defense Advanced Research Projects Agency* (DARPA), agence du département de la Défense des États-Unis, joue un rôle précurseur dans le développement de l’intelligence artificielle depuis les années 1960. Bien que ses travaux soient principalement orientés vers des applications militaires et de sécurité nationale, ils ont profondément influencé le paysage civil de l’IA et les réflexions internationales sur l’éthique algorithmique.

2.2.1 Programmes majeurs liés à l’IA

XAI — Explainable Artificial Intelligence (2017–2021)

Le programme **XAI** (*Explainable Artificial Intelligence*) est particulièrement pertinent pour notre projet. Lancé en 2017, il visait à développer des techniques permettant aux systèmes d’IA de **justifier leurs décisions** de manière compréhensible par un opérateur humain. Ce programme a donné naissance à des outils aujourd’hui largement utilisés dans le monde civil, notamment les méthodes d’explicabilité post-hoc (SHAP [26], LIME [27]) que nous mobilisons dans ce projet. L’idée fondatrice de XAI — qu’un modèle performant

mais opaque est insuffisant pour la prise de décision — est devenue un principe central de l’AI Act européen [25].

AI Next Campaign (2018–présent)

Lancée en 2018 avec un investissement de plus de 2 milliards de dollars, la campagne **AI Next** explore la « troisième vague » de l’IA : des systèmes capables non seulement de classer et prédire, mais aussi de **comprendre le contexte**, raisonner et s’adapter à de nouvelles situations. Cette vision dépasse les modèles statistiques que nous utilisons dans ce projet, mais elle illustre la trajectoire vers des systèmes d’IA de plus en plus autonomes — et donc les enjeux croissants de supervision humaine.

KAAS — Knowledge-directed Artificial Intelligence Reasoning Over Schemas

Ce programme développe des systèmes capables de raisonnement contextuel en intégrant des connaissances structurées. Dans le domaine RH, une telle approche permettrait à un modèle de prédiction de l’attrition de prendre en compte des facteurs contextuels (conjoncture économique, restructuration en cours) qui ne figurent pas dans les données tabulaires.

LwLL — Learning with Less Labels

Le programme **LwLL** vise à réduire la dépendance des modèles d’IA aux grands volumes de données étiquetées. Cet enjeu est directement pertinent pour les projets RH, où les données sont souvent limitées en volume (quelques milliers d’employés) et où l’étiquetage (départ effectif vs maintien) ne concerne qu’une minorité de cas — exactement le déséquilibre 84/16 que nous observons dans notre jeu de données.

2.2.2 Influence sur l’éthique de l’IA

Les travaux de la DARPA ont contribué à structurer le débat international sur l’IA responsable de plusieurs manières :

- **Explicabilité comme exigence opérationnelle** : le programme XAI a démontré que la transparence des modèles n’est pas seulement une question éthique mais une nécessité pratique pour la confiance et l’adoption ;
- **Robustesse et fiabilité** : les travaux sur l’IA adversariale (*Guaranteeing AI Robustness against Deception*, GARD) ont mis en lumière la vulnérabilité des modèles aux perturbations, renforçant l’exigence de robustesse que l’on retrouve dans l’AI Act ;
- **Approche centrée sur l’humain** : la doctrine *human-in-the-loop* (humain dans la boucle), née dans le contexte militaire, est devenue un pilier de la régulation européenne (article 14 de l’AI Act sur la supervision humaine).

Si l’approche américaine reste globalement moins réglementaire que l’eupéenne — les États-Unis privilégient l’autorégulation sectorielle et les lignes directrices volontaires — les contributions techniques de la DARPA ont paradoxalement fourni les outils (explicabilité, robustesse, audit) qui permettent aujourd’hui de satisfaire les exigences contraignantes de l’AI Act.

2.3 Définitions : éthique et équité en intelligence artificielle

Avant d’appliquer les principes réglementaires à notre projet, il est essentiel de définir précisément deux notions fondamentales qui traversent l’ensemble du cadre juridique et

technique : l'éthique et l'équité.

2.3.1 L'éthique en intelligence artificielle

Définition

L'**éthique de l'IA** désigne la branche de la philosophie morale appliquée aux systèmes d'intelligence artificielle. Elle interroge les principes et les valeurs qui doivent guider la conception, le développement, le déploiement et l'utilisation des systèmes d'IA. Contrairement à la réglementation, qui impose des obligations juridiques, l'éthique relève d'une démarche volontaire et réflexive visant à déterminer ce qui est *juste, bon* et *souhaitable* dans l'usage de ces technologies [9].

Dimensions de l'éthique en IA

L'éthique de l'IA se décline selon plusieurs dimensions complémentaires :

- **Éthique de la conception** (*ethics by design*) : intégrer les principes éthiques dès la phase de développement du système, et non comme un correctif a posteriori. Cela implique par exemple de choisir des métriques d'évaluation qui reflètent les valeurs souhaitées (recall plutôt qu'accuracy dans notre cas, pour ne pas invisibiliser les départs) ;
- **Éthique de l'usage** : s'assurer que le système est utilisé conformément à sa finalité déclarée. Un modèle de prédiction de l'attrition conçu pour améliorer les conditions de travail ne doit pas être détourné pour surveiller ou sanctionner les employés ;
- **Éthique de la responsabilité** : définir clairement qui est responsable des décisions prises avec l'aide du système — le développeur, l'entreprise utilisatrice, le manager qui agit sur la prédiction ? ;
- **Éthique des données** : questionner la légitimité de la collecte, la représentativité des données d'entraînement et le respect de la vie privée des personnes concernées.

Application à notre projet

Dans le contexte de la prédiction de l'attrition chez HumanForYou, l'éthique nous impose de nous poser plusieurs questions fondamentales : est-il légitime de prédire le comportement futur d'un employé à partir de ses données personnelles ? Le bénéfice attendu (rétention, amélioration des conditions) justifie-t-il l'intrusion dans la vie professionnelle ? Comment garantir que les prédictions ne stigmatisent pas certains profils d'employés ?

2.3.2 L'équité en intelligence artificielle

Définition

L'**équité algorithmique** (*fairness*) désigne la propriété d'un système d'IA à traiter de manière juste et non discriminatoire les individus ou les groupes, indépendamment de leurs caractéristiques protégées (genre, âge, origine ethnique, statut marital, etc.). L'équité ne se réduit pas à l'absence de discrimination intentionnelle : un modèle peut être discriminatoire de manière indirecte, en reproduisant ou en amplifiant des biais présents dans les données historiques [20].


Les différentes définitions mathématiques de l'équité

L'un des défis majeurs de l'équité algorithmique est qu'il n'existe pas de définition unique et universelle. Plusieurs métriques, parfois contradictoires entre elles, coexistent :

- **Parité démographique** (*demographic parity*) : le taux de prédiction positive doit être identique entre les groupes. Formellement : $P(\hat{Y} = 1 \mid A = a) = P(\hat{Y} = 1 \mid A = b)$ pour tout attribut protégé A ;
- **Égalité des chances** (*equalized odds*) : les taux de vrais positifs (recall) et de faux positifs doivent être identiques entre les groupes : $P(\hat{Y} = 1 \mid Y = y, A = a) = P(\hat{Y} = 1 \mid Y = y, A = b)$ pour $y \in \{0, 1\}$;
- **Calibration** (*predictive parity*) : la probabilité qu’une prédiction positive soit correcte doit être la même entre les groupes : $P(Y = 1 \mid \hat{Y} = 1, A = a) = P(Y = 1 \mid \hat{Y} = 1, A = b)$;
- **Équité individuelle** : des individus similaires doivent recevoir des prédictions similaires, indépendamment de leur appartenance à un groupe.

Le théorème d’impossibilité

Un résultat fondamental en équité algorithmique, démontré par Chouldechova (2017) [17] et Kleinberg *et al.* (2017) [18], établit qu’il est **mathématiquement impossible de satisfaire simultanément** la parité démographique, l’égalité des chances et la calibration, sauf dans le cas trivial où les taux de base sont identiques entre les groupes. Ce théorème impose un **choix éthique explicite** : quelle définition de l’équité est la plus pertinente pour le contexte d’usage ? La figure 3 illustre cette incompatibilité.



Sauf dans le cas trivial où les taux de base sont identiques entre les groupes, ces trois critères ne peuvent être satisfaits simultanément.

FIGURE 3 – Théorème d’impossibilité de l’équité algorithmique [17, 18] : les trois principales définitions de la *fairness* sont mutuellement incompatibles dans le cas général.

Application à notre projet

Dans le contexte RH de HumanForYou, nous privilégions l’**égalité des chances** comme métrique d’équité principale. En effet, il est essentiel que le modèle détecte les employés à risque avec la même efficacité quel que soit leur genre ou leur âge. Une parité démographique stricte serait moins pertinente, car les taux d’attrition réels peuvent

légitimement varier entre groupes en raison de facteurs structurels (conditions de travail différentes selon les départements, par exemple). L'exploration a montré un écart d'attrition faible entre genres (16,7 % vs 15,3 %), ce qui est encourageant.

2.4 Décisions et règles adoptées pour le projet

À la lumière du cadre réglementaire (RGPD, AI Act) et des sept principes éthiques du HLEG, nous structurons ci-dessous les **décisions** et les **règles** que nous nous engageons à suivre tout au long de ce projet, en les organisant selon les sept exigences pour une IA digne de confiance [4, 3].

2.4.1 Respect de l'autonomie humaine

Principe général

Le HLEG définit cette exigence comme suit : « les systèmes d'IA sont développés et utilisés comme un outil au service des personnes, qui respecte la dignité humaine et l'autonomie personnelle, et qui fonctionne d'une manière qui peut être contrôlée et supervisée de manière appropriée par les êtres humains » [3]. L'article 22 du RGPD interdit les décisions fondées exclusivement sur un traitement automatisé produisant des effets juridiques ou significatifs. La CNIL insiste sur la nécessité de « concevoir des systèmes au service de la liberté humaine » [9], tandis que le rapport Villani prône la « complémentarité homme-machine » [11].

Application à notre projet

Le modèle de prédiction de l'attrition est strictement positionné comme un **outil d'aide à la décision**. Aucune action RH (entretien, formation, mobilité, ajustement salarial) ne pourra être déclenchée automatiquement par une prédiction du modèle. Le système a pour unique finalité l'**amélioration de la rétention des talents et des conditions de travail**. Il est interdit de l'utiliser à des fins de surveillance, de sanction, de classement des employés ou de justification de licenciements.

Mise en œuvre concrète

1. **Validation humaine obligatoire.** Toute prédiction d'attrition doit être examinée par un responsable RH qualifié avant qu'une quelconque action ne soit envisagée. Le modèle produit un score de risque et des facteurs explicatifs, mais c'est le responsable RH qui décide de la suite à donner (entretien, proposition de formation, ajustement de poste).
2. **Charte d'utilisation.** Nous rédigerons une charte définissant les usages autorisés et interdits du système, signée par tous les utilisateurs ayant accès au tableau de bord de prédiction.
3. **Tableau de bord consultatif.** L'interface de restitution des résultats sera conçue comme un outil de consultation (alertes, visualisations, facteurs SHAP) et non comme un système de notification automatique déclenchant des workflows RH.
4. **Information préalable des employés.** Conformément au RGPD, les employés seront informés de l'existence du système, de sa finalité, des données utilisées et de leur droit d'opposition, via une note d'information claire et accessible.

Illustration par les données

Le jeu de données contient des variables d'évaluation managériale (`PerformanceRating`, `JobInvolvement`) attribuées par des êtres humains, non par un algorithme. Sur les 4 410 employés, 84,7 % des évaluations de performance attribuent un score de 3 (« excellent »), ce qui montre que ces jugements sont déjà le fruit d'une appréciation humaine. Le modèle ne remplace pas ce jugement : il le complète en identifiant des signaux faibles de départ que le manager peut ensuite contextualiser.

2.4.2 Robustesse technique et sécurité

Principe général

Le HLEG exige que « les systèmes d'IA soient développés et utilisés d'une manière qui permet la robustesse en cas de problèmes et la résilience contre les tentatives d'altérer l'utilisation ou la performance du système, de manière à minimiser les dommages involontaires » [3]. Le guide de sécurité de la CNIL [10] décline cette exigence en mesures concrètes de protection des données. La CNIL recommande également de « former à l'éthique tous les acteurs de la chaîne algorithmique » pour réduire les risques d'erreur [9].

Application à notre projet

La robustesse technique se traduit par plusieurs règles de conception et de validation du pipeline de données et de modélisation.

Mise en œuvre concrète

1. **Validation croisée stratifiée.** Le jeu de données étant déséquilibré (16 % d'attrition), nous utiliserons une validation croisée stratifiée (5 ou 10 folds) pour garantir que chaque fold conserve la même proportion de classes. Cela évite le surapprentissage sur la classe majoritaire et assure une estimation fiable des performances.
2. **Traitement rigoureux des valeurs manquantes.** Les 111 valeurs manquantes identifiées sur 5 variables (`NumCompaniesWorked`, `TotalWorkingYears`, `EnvironmentSatisfaction`, `JobSatisfaction`, `WorkLifeBalance`) seront imputées par la médiane (variables numériques) ou le mode (variables catégorielles), avec documentation du choix et de son impact sur les résultats.
3. **Suppression des variables constantes.** Les variables `EmployeeCount` (= 1), `Over18` (= Y) et `StandardHours` (= 8) sont supprimées dès le prétraitement car elles n'apportent aucune information discriminante mais pourraient introduire du bruit.
4. **Agrégation robuste des données de badgeage.** Plutôt que d'utiliser les 365 horodatages bruts (sujets aux valeurs manquantes ponctuelles), nous dérivons des variables agrégées (`avg_work_hours`, `std_work_hours`, `nb_days_absent`) qui résistent aux absences ponctuelles.
5. **Documentation des limites.** Le caractère transversal des données (coupe 2015–2016) est explicitement documenté comme limite : le modèle ne capture pas l'évolution temporelle des facteurs d'attrition, ce qui réduit sa fiabilité pour un déploiement à long terme sans réentraînement.

Illustration par les données

Les données de badgeage (`in_time.csv`, `out_time.csv`) couvrent 365 jours de l'année 2015 pour chacun des 4 410 employés. Des valeurs `NA` sont présentes lorsqu'un employé est absent, ce qui nécessite un traitement robuste : nous dérivons des variables agrégées (`avg_work_hours`, `std_work_hours`, `nb_days_absent`) plutôt que d'utiliser les horodateurs bruts, ce qui rend le modèle plus résilient aux données manquantes ponctuelles.

2.4.3 Confidentialité et gouvernance des données

Principe général

Le HLEG exige que « les systèmes d'IA soient développés et utilisés conformément aux règles de protection de la vie privée et des données, tout en traitant des données qui répondent à des normes élevées en termes de qualité et d'intégrité » [3]. Le RGPD impose les principes de minimisation des données (article 5), de pseudonymisation et de conservation limitée. La CNIL recommande de « constituer une plateforme nationale d'audit des algorithmes » pour vérifier la conformité des traitements [9]. Le rapport Villani souligne l'importance d'une « politique économique centrée sur les données » comme fondement stratégique [11].

Application à notre projet

Le traitement des données RH impose des mesures strictes de protection de la vie privée et de gouvernance de la qualité des données.

Mise en œuvre concrète

1. **Minimisation des données.** Nous supprimons dès le prétraitement toute variable non nécessaire à la prédiction : les variables constantes (`EmployeeCount = 1`, `Over18 = Y`, `StandardHours = 8`) ainsi que toute variable redondante identifiée par analyse de corrélation. Le jeu de données final ne conserve que les variables ayant un pouvoir prédictif démontré.
2. **Pseudonymisation native.** Les données sont manipulées exclusivement via l'identifiant numérique `EmployeeID`. Aucune donnée nominative (nom, prénom, adresse, numéro de téléphone) n'est présente ni dans les fichiers sources ni dans les sorties du modèle. En cas de déploiement, aucune table de correspondance `EmployeeID ↔ identité` ne sera accessible aux opérateurs du modèle.
3. **Conservation limitée.** Les données et le modèle sont conservés uniquement pour la durée de l'analyse académique. Tout déploiement opérationnel nécessiterait une **analyse d'impact relative à la protection des données** (AIPD) préalable, conformément à l'article 35 du RGPD.
4. **Contrôle de qualité des données.** Avant toute modélisation, nous documenterons un rapport de qualité des données : taux de valeurs manquantes par variable, distributions atypiques, et vérification de la cohérence entre les quatre sources (données générales, enquêtes, évaluations, badgeage).
5. **Vérification de l'absence de données sensibles.** Nous confirmons que le jeu de données ne contient aucune catégorie de données sensibles au sens de l'article 9 du RGPD (origines ethniques, opinions politiques, données de santé, orientation sexuelle). Les variables `Gender`, `MaritalStatus` et `Age`, bien qu'elles soient des attributs protégés, ne relèvent pas de l'article 9.

Illustration par les données

Le jeu de données comprend 35 variables dans sa version fusionnée. Parmi celles-ci, les données salariales (`MonthlyIncome`), les évaluations de satisfaction (`JobSatisfaction`, `EnvironmentSatisfaction`) et les horaires de badgeage constituent des données personnelles relevant du RGPD. Cependant, l'identification directe est impossible : seul un identifiant numérique (`EmployeeID` de 1 à 4410) est utilisé, sans table de correspondance avec des données nominatives. La gouvernance des données impose de vérifier la qualité : nous avons identifié 111 valeurs manquantes réparties sur `NumCompaniesWorked` (19), `TotalWorkingYears` (9), `EnvironmentSatisfaction` (25), `JobSatisfaction` (20) et `WorkLifeBalance` (38).

2.4.4 Transparence

Principe général

Le HLEG définit la transparence comme l'obligation de développer des systèmes d'IA « de manière à permettre une traçabilité et une explicabilité appropriées, tout en faisant prendre conscience aux humains qu'ils communiquent ou interagissent avec un système d'IA, ainsi qu'en informant dûment les déployeurs des capacités et des limites de ce système et les personnes concernées de leurs droits » [3]. La CNIL appelle à « rendre les systèmes algorithmiques compréhensibles » [9]. Le Centre de politique européenne rappelle que la transparence est un prérequis pour la confiance dans les systèmes d'IA [5].

Application à notre projet

La transparence est essentielle pour que les responsables RH puissent faire confiance aux prédictions et que les employés comprennent comment le système les concerne.

Mise en œuvre concrète

1. **Explicabilité individuelle via SHAP.** Pour chaque employé identifié comme « à risque », nous générerons un graphique SHAP (*waterfall plot*) montrant la contribution de chaque variable à la prédiction. Le responsable RH pourra ainsi voir, par exemple, que le risque de départ d'un employé est principalement lié à ses heures de travail excessives et à un faible score de satisfaction, plutôt qu'à son âge ou son genre.
2. **Explicabilité globale.** Nous produirons un classement global des facteurs d'attrition (*SHAP summary plot*) à l'échelle de l'entreprise, permettant à la direction RH d'identifier les leviers structurels (conditions de travail, politique salariale, management) sur lesquels agir en priorité.
3. **Documentation technique complète.** Conformément à l'AI Act, nous livrerons une documentation décrivant : (a) les données utilisées et leur provenance, (b) les choix de prétraitement et de modélisation, (c) les performances obtenues (accuracy, recall, precision, F1, AUC) et leur interprétation, (d) les limites identifiées et les conditions de validité du modèle.
4. **Information des employés.** Une note d'information rédigée en langage clair sera mise à disposition de tous les employés, précisant : l'existence du système, sa finalité (amélioration des conditions de travail), les catégories de données utilisées, les droits de la personne (accès, rectification, opposition, explication) et les coordonnées du responsable du traitement.

5. **Traçabilité du pipeline.** Chaque étape du traitement (fusion des sources, imputation des valeurs manquantes, encodage des variables catégorielles, entraînement, évaluation) sera documentée et reproductible via des scripts versionnés, permettant un audit technique complet.

Illustration par les données

Le jeu de données repose sur quatre sources distinctes : données générales (24 variables), enquête de satisfaction employé (3 variables sur échelle de Likert 1–4), évaluation managériale (2 variables) et données de badgeage (365 jours d’horodatages). La transparence exige de documenter chaque étape de fusion de ces sources, les choix d’agrégation (par exemple, la transformation de 365 horodatages en `avg_work_hours` et `nb_days_absent`) et les éventuelles pertes d’information associées. Le fait que l’échelle de satisfaction aille de 1 (« Low ») à 4 (« Very High ») doit être explicité pour que les destinataires des prédictions puissent interpréter les facteurs SHAP.

2.4.5 Diversité, non-discrimination et équité

Principe général

Le HLEG exige que les systèmes d’IA soient « développés et utilisés de manière à inclure divers acteurs et à promouvoir l’égalité d’accès, l’égalité des sexes et la diversité culturelle, tout en évitant les effets discriminatoires et les préjugés injustes interdits par le droit de l’Union ou le droit national » [3]. Le rapport Villani inscrit l’**inclusivité et la diversité** comme dimension transversale de la stratégie nationale en IA [11]. Le Hub France IA propose des méthodologies concrètes d’audit d’équité [12], et Quantmetry détaille les métriques d’équité algorithmique (parité démographique, égalité des chances, calibration) [20].

Application à notre projet

Les données présentent des déséquilibres structurels (genre, âge, statut marital) que le modèle pourrait reproduire ou amplifier. Nous mettons en place un cadre d’équité systématique.

Mise en œuvre concrète

1. **Conservation des attributs protégés pour audit.** Les variables `Gender`, `MaritalStatus` et `Age` sont conservées dans le modèle plutôt que supprimées. Leur suppression pourrait paradoxalement dégrader l’équité si d’autres variables en sont des proxys (par exemple, `MonthlyIncome` corrélé au genre, ou `TotalWorkingYears` corrélé à l’âge). En les conservant, nous pouvons explicitement mesurer et contrôler leur influence.
2. **Audit d’équité systématique post-entraînement.** Après chaque entraînement, nous calculerons les métriques d’équité suivantes, ventilées par genre (Male/Female), par tranche d’âge (18–30, 31–40, 41–50, 51+) et par statut marital (Single, Married, Divorced) :
 - *Recall* (taux de vrais positifs) par sous-groupe ;
 - *Taux de faux positifs* par sous-groupe ;
 - *Parité démographique* : proportion de prédictions positives par sous-groupe.

Un écart supérieur à **5 points de pourcentage** entre sous-groupes sur l’une de ces métriques déclenchera une investigation formelle.

3. **Débiaisage post-traitement si nécessaire.** Si un biais significatif est détecté, nous appliquerons un ajustement des seuils de décision par sous-groupe (*threshold adjustment*), méthode qui corrige les disparités sans modifier le modèle lui-même. Si cette approche est insuffisante, nous envisagerons un rééchantillonnage (*oversampling* de la classe minoritaire dans le sous-groupe défavorisé) ou une régularisation du modèle pénalisant les disparités.
4. **Analyse des proxys.** Nous vérifierons par analyse de corrélation et par SHAP que les variables non protégées (comme `MonthlyIncome`, `JobLevel`, `Department`) ne servent pas de proxys discriminatoires pour les attributs protégés. Si une variable non protégée est fortement corrélée à un attribut protégé *et* contribue de manière disproportionnée aux prédictions, elle sera signalée et son rôle sera examiné.

Illustration par les données

Les données révèlent des disparités qu'un modèle non audité pourrait reproduire ou amplifier. Le taux d'attrition varie selon le genre (15,3 % pour les femmes contre 16,7 % pour les hommes), le statut marital (25,5 % pour les célibataires contre 10,1 % pour les divorcés) et l'âge (25,9 % pour les 18–30 ans contre 10,6 % pour les 41–50 ans). La répartition par genre est déséquilibrée (2 646 hommes, 1 764 femmes, soit 60/40), tandis que les revenus moyens sont proches (65 319 pour les hommes, 64 595 pour les femmes). Le département « Human Resources » affiche un taux d'attrition de 30,2 %, nettement supérieur aux autres départements (15 %). Ces déséquilibres justifient l'audit d'équité systématique inscrit dans nos règles.

2.4.6 Bien-être environnemental et sociétal

Principe général

Le HLEG exige que les systèmes d'IA soient « développés et utilisés d'une manière durable et respectueuse de l'environnement, ainsi que dans l'intérêt de tous les êtres humains, tout en surveillant et en évaluant les incidences à long terme sur l'individu, la société et la démocratie » [3]. Le rapport Villani identifie les « enjeux écologiques » comme dimension transversale et insiste sur l'anticipation des impacts sur l'emploi et la « cohésion sociale » [11]. La CNIL rappelle que « tous les algorithmes doivent servir les intérêts des utilisateurs, en tant que citoyens et communautés », au-delà de leur statut de consommateurs [9].

Application à notre projet

Le bien-être sociétal est au cœur de la finalité du système : il vise à améliorer les conditions de travail et la rétention des talents, et non à maximiser la productivité au détriment des employés.

Mise en œuvre concrète

1. **Orientation vers les leviers d'amélioration.** Les recommandations issues du modèle cibleront exclusivement des **actions positives** : propositions de formation, ajustement de la charge de travail, amélioration des conditions d'environnement, mobilité interne. Le système ne sera jamais utilisé pour identifier des individus à sanctionner, surveiller ou licencier.
2. **Suivi des indicateurs de bien-être.** Les variables de satisfaction (`WorkLifeBalance`, `EnvironmentSatisfaction`, `JobSatisfaction`) et les données de charge de travail

(`avg_work_hours`, `std_work_hours`) seront utilisées non seulement comme prédicteurs mais aussi comme **indicateurs de suivi** : une dégradation globale de ces scores signalera un problème organisationnel nécessitant une action structurelle, au-delà du cas individuel.

3. **Empreinte environnementale maîtrisée.** L'impact environnemental est limité par le choix de modèles légers (forêts aléatoires, gradient boosting) ne nécessitant pas d'infrastructure GPU intensive, et par l'utilisation d'un jeu de données de taille modeste (4 410 observations, 35 variables). En cas de déploiement, le réentraînement annuel (plutôt que continu) limitera la consommation de ressources de calcul.
4. **Évaluation de l'impact sociétal.** Avant tout déploiement opérationnel, une évaluation de l'impact du système sur les relations de travail sera conduite : le système ne doit pas générer de climat de surveillance ou de méfiance entre employés et management. Les représentants du personnel seront consultés pour valider l'acceptabilité du dispositif.

Illustration par les données

Les données de satisfaction (`WorkLifeBalance`, `EnvironmentSatisfaction`, `JobSatisfaction`) mesurent directement le bien-être des employés. Sur les 4 410 employés, 239 (5,4 %) déclarent un équilibre vie professionnelle-vie personnelle « Low » (score de 1) et 1 019 (23,1 %) un score de 2. Les heures de travail dérivées du badgeage (`avg_work_hours`, `std_work_hours`) permettent de détecter des situations de surcharge. Le modèle peut ainsi contribuer à identifier les populations les plus exposées au mal-être professionnel, à condition que les recommandations qui en découlent servent l'amélioration des conditions de travail.

2.4.7 Responsabilité

Principe général

Le HLEG exige la « mise en œuvre de mécanismes garantissant la responsabilité et l'obligation de rendre des comptes pour les systèmes d'IA et leurs résultats » [3]. La CNIL insiste sur la « vigilance et la réflexivité » : un « questionnement régulier et méthodique des systèmes algorithmiques par tous les acteurs (concepteurs, entreprises, citoyens) » [9]. Elle recommande de « renforcer la fonction éthique dans les entreprises » et de « constituer une plateforme nationale d'audit des algorithmes » [9]. Les lignes directrices de la Commission européenne soulignent l'importance de la traçabilité pour la reddition de comptes [6].

Application à notre projet

La responsabilité exige des mécanismes concrets de reddition de comptes, de traçabilité et de recours pour les personnes concernées.

Mise en œuvre concrète

1. **Supervision humaine continue.** Les prédictions alimentent un tableau de bord consultatif accessible aux responsables RH. Le modèle ne déclenche aucune action automatique. Chaque consultation du tableau de bord et chaque décision prise à la suite d'une alerte seront journalisées pour assurer la traçabilité des usages.
2. **Réentraînement et audit périodique.** En cas de déploiement opérationnel, le modèle sera réentraîné annuellement sur les données les plus récentes. Un audit complet sera conduit à chaque cycle : performances (accuracy, recall, F1), équité

(métriques ventilées par genre, âge, statut), et dérive (*model drift*) par comparaison des distributions d'entrée et de sortie entre périodes.

3. **Droit de contestation individuel.** Tout employé pourra demander une explication de sa classification via un interlocuteur humain désigné (responsable RH ou référent éthique). La procédure de contestation sera documentée et accessible. En cas de contestation, le système produira un rapport SHAP individuel détaillant les facteurs ayant contribué à la prédiction.
4. **Comité de supervision.** Le déploiement opérationnel nécessitera la constitution d'un comité de supervision incluant : des représentants RH, des représentants du personnel, un référent éthique et, si possible, un profil technique capable d'auditer le modèle. Ce comité se réunira au minimum une fois par semestre pour examiner les résultats, les contestations et les éventuels biais détectés.
5. **Registre des traitements.** Conformément à l'article 30 du RGPD, un registre des traitements sera tenu, documentant : la finalité du système, les catégories de données traitées, les destinataires des résultats, les durées de conservation et les mesures de sécurité appliquées.

Illustration par les données

La traçabilité s'appuie sur la clé `EmployeeID` qui permet de relier chaque prédiction à son dossier source, sans rompre la pseudonymisation. Les quatre sources de données (données générales, enquête employé, évaluation managériale, badgeage) sont fusionnées via cette clé, ce qui garantit l'auditabilité complète du pipeline. En cas de contestation, il est possible de retrouver pour chaque individu les valeurs exactes ayant alimenté le modèle : par exemple, pour l'employé 2 (femme, célibataire, 31 ans, `Research Scientist`, revenu de 41 890, satisfaction environnement de 3, équilibre vie pro de 4), le système peut expliquer via SHAP quels facteurs ont conduit à la prédiction « Yes » (attrition).

2.5 Application au projet HumanForYou sous le cadre européen

En nous plaçant dans le cadre réglementaire européen, notre projet de prédiction de l'attrition doit respecter plusieurs exigences.

Protection des données personnelles

Les données utilisées contiennent des informations sensibles sur les employés : salaire, évaluations de performance, satisfaction, horaires de travail, statut marital. La **pseudonymisation** (identifiants numériques plutôt que noms) est déjà appliquée dans le jeu de données via la clé `EmployeeID`, ce qui constitue une bonne pratique conforme au RGPD.

Risques de biais et de discrimination

Certaines variables du jeu de données — telles que `Gender`, `MaritalStatus`, `Age` ou `Education` — sont des attributs protégés susceptibles d'introduire des biais discriminatoires dans le modèle. Il sera nécessaire de :

- Mesurer l'impact de ces variables sur les prédictions ;
- Évaluer l'équité du modèle selon différentes métriques (parité démographique, égalité des chances, etc.) ;
- Le cas échéant, appliquer des techniques de débiaisage.

Transparence et explicabilité

Conformément aux principes du HLEG et aux exigences de l’AI Act, le modèle doit être **interprétable** : il ne suffit pas de prédire l’attrition, il faut être en mesure d’expliquer *pourquoi* un employé est identifié comme à risque. L’utilisation de techniques d’explicabilité (importance des variables, SHAP [26], LIME [27], etc.) sera privilégiée.

Supervision humaine

Les résultats du modèle doivent servir d’**aide à la décision** et non de décision automatique. Toute action RH fondée sur les prédictions (entretien, formation, ajustement salarial) doit impliquer un jugement humain qualifié, conformément à l’article 22 du RGPD.

Finalité et proportionnalité

Le modèle doit être utilisé dans une finalité légitime : **la rétention des talents et l’amélioration des conditions de travail**, et non la surveillance ou la sanction des employés. Cette distinction est fondamentale pour garantir la conformité éthique et juridique du projet.

La figure 4 synthétise l’architecture complète du pipeline, de la collecte des données à la décision humaine, en indiquant les garanties éthiques et réglementaires appliquées à chaque étape.




FIGURE 4 – Architecture du pipeline de prédiction de l’attrition avec garanties éthiques et réglementaires intégrées à chaque étape.

3 Conclusion

Ce projet a permis de mener une analyse complète du turnover chez HumanForYou, de l’exploration des données à la formulation de recommandations stratégiques, en passant par la construction de modèles prédictifs.

Trois résultats clés se dégagent. Premièrement, la surcharge horaire est le premier facteur d’attrition — un résultat obtenu grâce aux données de badgeage, souvent sous-exploitées. Deuxièmement, le profil type de l’employé à risque est un jeune collaborateur, récemment arrivé, avec un nouveau manager et des déplacements fréquents. Troisièmement, les modèles ensemblistes (forêt aléatoire, gradient boosting) surpassent nettement la régression logistique, confirmant la présence d’interactions non linéaires entre facteurs.

L’ancrage réglementaire dans le cadre européen (RGPD, AI Act) a guidé chaque étape : pseudonymisation des données, conservation des attributs protégés avec analyse de biais, explicabilité via SHAP, et positionnement strict du modèle comme aide à la décision — jamais comme système autonome. Ce cadre offre des garanties de confiance essentielles pour l’acceptabilité du système par les employés.

Limites et perspectives. Le jeu de données est une coupe transversale (2015–2016) ; un suivi longitudinal permettrait de capturer l’évolution des facteurs dans le temps. L’intégration de données qualitatives (entretiens de sortie, verbatims d’enquêtes) enrichirait la compréhension des motifs de départ. Enfin, le déploiement effectif du modèle nécessiterait une **analyse d’impact relative à la protection des données** (AIPD) et la constitution d’un comité de supervision, conformément aux obligations pour les systèmes à haut risque.

Références

- [1] Parlement européen et Conseil de l'Union européenne, *Règlement (UE) 2016/679 relatif à la protection des personnes physiques à l'égard du traitement des données à caractère personnel et à la libre circulation de ces données (RGPD)*, Journal officiel de l'Union européenne, 27 avril 2016, <https://eur-lex.europa.eu/legal-content/FR/TXT/?uri=CELEX:32016R0679>.
CONCEPTS : protection des données personnelles, consentement, minimisation des données, pseudonymisation, droit d'opposition, décision automatisée (art. 22), AIPD (art. 35), registre des traitements (art. 30).
- [2] CNIL, *Comprendre le RGPD*, <https://www.cnil.fr/fr/comprendre-le-rgpd>.
CONCEPTS : vulgarisation du RGPD, droits des personnes, obligations des responsables de traitement, bases légales.
- [3] Parlement européen et Conseil de l'Union européenne, *Règlement (UE) 2024/1689 établissant des règles harmonisées concernant l'intelligence artificielle (AI Act)*, Journal officiel, 13 juin 2024. Considérant 27, <https://artificialintelligenceact.eu/fr/recital/27/>.
CONCEPTS : classification des risques IA, systèmes à haut risque (annexe III), IA en RH, supervision humaine (art. 14), interdiction de la notation sociale (art. 5), gouvernance des données, documentation technique, sept principes HLEG.
- [4] Groupe d'experts de haut niveau sur l'IA, *Lignes directrices en matière d'éthique pour une IA digne de confiance*, Commission européenne, 2019, https://ec.europa.eu/newsroom/dae/document.cfm?doc_id=60427.
CONCEPTS : sept exigences éthiques (autonomie humaine, robustesse, vie privée, transparence, diversité/équité, bien-être sociétal, responsabilité), IA centrée sur l'humain, reddition de comptes.
- [5] Centre de politique européenne, *Lignes directrices en matière d'éthique pour l'IA : analyse de la communication COM(2019) 168*, https://www.cep.eu/fileadmin/user_upload/cep.eu/Analysen/COM_2019_168_Ethik_in_KI/CA_COM_2019_168_Lignes_directrices_en_matiere_d_ethique_pour_l_IA.pdf.
CONCEPTS : transparence algorithmique, confiance dans l'IA, analyse de la communication européenne sur l'éthique de l'IA.
- [6] Commission européenne, *Lignes directrices relatives à l'utilisation de l'intelligence artificielle*, 2022, https://teachertaskforce.org/sites/default/files/2023-06/2022_EC_lignes-directrices-utilisation-IA_FR.pdf.
CONCEPTS : traçabilité, reddition de comptes, supervision humaine, bonnes pratiques d'utilisation de l'IA.
- [7] Loi n° 78-17 du 6 janvier 1978 relative à l'informatique, aux fichiers et aux libertés, *Journal officiel de la République française*, 7 janvier 1978, <https://www.legifrance.gouv.fr/loda/id/JORFTEXT000000886460>.
CONCEPTS : naissance de la protection des données en France, création de la CNIL, réaction au projet SAFARI, fichage administratif, libertés individuelles.
- [8] Boucher, P., « SAFARI ou la chasse aux Français », *Le Monde*, 21 mars 1974.
CONCEPTS : projet SAFARI, interconnexion des fichiers administratifs, numéro de sécurité sociale, fichage de masse, alerte journalistique.

- [9] CNIL, *Comment permettre à l'Homme de garder la main ? Rapport sur les enjeux éthiques des algorithmes et de l'intelligence artificielle*, décembre 2017, <https://www.cnil.fr/fr/comment-permettre-lhomme-de-garder-la-main-rapport-sur-les-enjeux-ethiques-des-a>.
CONCEPTS : loyauté algorithmique, vigilance et réflexivité, éthique par conception, formation à l'éthique, audit des algorithmes, fonction éthique en entreprise.
- [10] CNIL, *Guide de la sécurité des données personnelles*, édition 2023, https://www.cnil.fr/sites/cnil/files/2023-04/cnil_guide_securite_des_donnees_personnelles-2023.pdf.
CONCEPTS : sécurité des données, mesures techniques et organisationnelles, intégrité, confidentialité, robustesse des systèmes.
- [11] Villani, C. et al., *Donner un sens à l'intelligence artificielle : pour une stratégie nationale et européenne*, rapport au Premier ministre, mars 2018, <https://www.vie-publique.fr/rapport/37225-donner-un-sens-lintelligence-artificielle-pour-une-strategie-nation>.
CONCEPTS : stratégie nationale IA, politique des données, transformation de l'emploi, enjeux écologiques, inclusivité et diversité, complémentarité homme-machine.
- [12] Hub France IA, *Guide pratique IA éthique*, version 2, décembre 2024, https://www.hub-franceia.fr/wp-content/uploads/2024/12/Guide_pratique_IA_ethique_version-2.pdf.
CONCEPTS : méthodologie d'audit d'équité, IA éthique en pratique, débiaisage, bonnes pratiques industrielles.
- [13] Greenwald, G. et MacAskill, E., « NSA Prism program taps in to user data of Apple, Google and others », *The Guardian*, 7 juin 2013, <https://www.theguardian.com/world/2013/jun/06/us-tech-giants-nsa-data>.
CONCEPTS : programme PRISM, surveillance de masse, NSA, XKeyscore, révélations Snowden, collecte de données sans consentement, accélération du RGPD.
- [14] CNIL, *Reconnaissance faciale : la CNIL sanctionne Clearview AI d'une amende de 20 millions d'euros*, 20 octobre 2022, <https://www.cnil.fr/fr/reconnaissance-faciale-la-cnil-met-en-demeure-clearview-ai-de-cesser-la-reutilis>.
CONCEPTS : reconnaissance faciale, collecte biométrique sans consentement, 3 milliards d'images, surveillance dans l'espace public, sanction CNIL.
- [15] Cadwalladr, C. et Graham-Harrison, E., « Revealed : 50 million Facebook profiles harvested for Cambridge Analytica in major data breach », *The Guardian*, 17 mars 2018, <https://www.theguardian.com/news/2018/mar/17/cambridge-analytica-facebook-influence-us-election>.
CONCEPTS : exploitation abusive de données personnelles, profilage psychologique, manipulation électorale, 87 millions d'utilisateurs Facebook, amende FTC de 5 milliards de dollars.
- [16] Angwin, J., Larson, J., Mattu, S. et Kirchner, L., « Machine Bias : There's software used across the country to predict future criminals. And it's biased against blacks », *ProPublica*, 23 mai 2016, <https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing>.
CONCEPTS : biais racial algorithmique, COMPAS, prédiction de récidive, faux positifs disproportionnés, opacité des systèmes de scoring, justice prédictive.

- [17] Chouldechova, A., « Fair prediction with disparate impact : A study of bias in recidivism prediction instruments », *Big Data*, vol. 5, n° 2, pp. 153–163, 2017. DOI : 10.1089/big.2016.0047.
 CONCEPTS : théorème d'impossibilité de l'équité, incompatibilité des métriques de fairness, parité démographique vs calibration, choix éthique explicite.
- [18] Kleinberg, J., Mullainathan, S. et Raghavan, M., « Inherent Trade-Offs in the Fair Determination of Risk Scores », *Proceedings of Innovations in Theoretical Computer Science (ITCS)*, 2017. arXiv :1609.05807, <https://arxiv.org/abs/1609.05807>.
 CONCEPTS : compromis fondamentaux en équité algorithmique, scores de risque, impossibilité de satisfaire simultanément calibration, équité prédictive et égalité des chances.
- [19] Destin, J., « Amazon scraps secret AI recruiting tool that showed bias against women », *Reuters*, 10 octobre 2018, <https://www.reuters.com/article/us-amazon-com-jobs-automation-insight-idUSKCN1MK08G>.
 CONCEPTS : biais de genre en recrutement IA, données d'entraînement biaisées, discrimination algorithmique indirecte, CV et biais sexistes, abandon de système IA.
- [20] Quantmetry (Capgemini), *Intelligence artificielle et éthique : comment définir et mesurer l'équité algorithmique*, <https://www.quantmetry.com/blog/intelligence-artificielle-et-ethique-comment-definir-et-mesurer-lequite-algorithmique>.
 CONCEPTS : définitions formelles de l'équité (parité démographique, égalité des chances, calibration), équité individuelle, métriques de fairness, mesure des biais.
- [21] Rosenblat, A. et Stark, L., « Algorithmic Labor and Information Asymmetries : A Case Study of Uber's Drivers », *International Journal of Communication*, vol. 10, pp. 3758–3784, 2016, <https://ijoc.org/index.php/ijoc/article/view/4892>.
 CONCEPTS : manipulation algorithmique des travailleurs, asymétrie d'information, prédiction d'attrition détournée, incitations ciblées, contrôle social par l'algorithme.
- [22] Electronic Privacy Information Center (EPIC), *Complaint and Request for Investigation of HireVue, Inc.*, déposé auprès de la Federal Trade Commission, 6 novembre 2019, <https://epic.org/documents/in-re-hirevue/>.
 CONCEPTS : analyse faciale en recrutement, entretien vidéo automatisé, opacité algorithmique, plainte pour pratiques déloyales, abandon de la reconnaissance faciale (2021).
- [23] Booth, R., « Barclays using 'Big Brother' tactics to spy on staff, says TUC », *The Guardian*, 20 février 2020, <https://www.theguardian.com/business/2020/feb/20/barclays-using-dystopian-big-brother-tactics-to-spy-on-staff-says-tuc>.
 CONCEPTS : surveillance des employés, traçage de la productivité en temps réel, limites de la surveillance algorithmique au travail, intervention de l'ICO.
- [24] Government of India, *Digital Personal Data Protection Act, 2023* (Act No. 22 of 2023), *The Gazette of India*, 11 août 2023, <https://www.meity.gov.in/writereaddata/files/Digital%20Personal%20Data%20Protection%20Act%202023.pdf>.
 CONCEPTS : protection des données personnelles en Inde, consentement, droits des personnes, contexte Aadhaar, pression internationale post-RGPD.
- [25] DARPA, *Explainable Artificial Intelligence (XAI) Program*, <https://www.darpa.mil/research/programs/explainable-artificial-intelligence>.
 CONCEPTS : explicabilité des modèles d'IA, justification des décisions algorithmiques, confiance opérateur-machine, origine des méthodes post-hoc (SHAP, LIME).

- [26] Lundberg, S.M. et Lee, S.-I., « A Unified Approach to Interpreting Model Predictions », *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, <https://papers.nips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>.

CONCEPTS : SHAP (SHapley Additive exPlanations), valeurs de Shapley, explicabilité locale et globale, contribution individuelle des variables, interprétation des modèles ensemblistes.

- [27] Ribeiro, M.T., Singh, S. et Guestrin, C., « ‘Why Should I Trust You ?’ : Explaining the Predictions of Any Classifier », *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 1135–1144, 2016. DOI : 10.1145/2939672.2939778, <https://doi.org/10.1145/2939672.2939778>.

CONCEPTS : LIME (Local Interpretable Model-agnostic Explanations), explicabilité locale, approximation linéaire locale, interprétabilité model-agnostic, confiance dans les classifieurs.