

Projet Bloc IA

Analyse du turnover chez HumanForYou

Maxence Chartier

Amine Haouri

Anisse Imerzoukene

Mourad Messaoudi

26 mars 2026

Table des matières

1	Introduction	3
2	Cadre réglementaire et éthique	3
2.1	Cadre réglementaire européen	3
2.1.1	Le Règlement Général sur la Protection des Données (RGPD) . . .	3
2.1.2	La loi européenne sur l'intelligence artificielle (AI Act)	4
2.1.3	Les sept principes éthiques pour une IA digne de confiance	5
2.1.4	Cadre français : contributions majeures	5
2.2	Application au projet HumanForYou sous le cadre européen	6
2.3	Bonus : cadre indien et comparaison	6
2.3.1	Le Digital Personal Data Protection Act (DPDPA, 2023)	7
2.3.2	Les India AI Governance Guidelines (2025)	7
2.3.3	Comparaison synthétique	7
3	Description des données	7
3.1	Données générales (<code>general_data.csv</code>)	7
3.2	Enquête employé (<code>employee_survey_data.csv</code>)	8
3.3	Évaluation manager (<code>manager_survey_data.csv</code>)	8
3.4	Horaires de badgeage (<code>in_out_time/</code>)	8
3.5	Jeu de données fusionné (<code>dataset_final.csv</code>)	8
4	Exploration des données	10
4.1	Déséquilibre de la variable cible	10
4.2	Qualité des données	10
4.3	Facteurs d'attrition : variables catégorielles	10
4.4	Facteurs d'attrition : variables numériques	11
4.5	Corrélations et sélection de variables	11
4.6	Synthèse des enseignements pour la suite	13
5	Prétraitement	13
5.1	Suppression des variables non informatives	13
5.2	Imputation des valeurs manquantes	13
5.3	Encodage des variables catégorielles	13
5.4	Standardisation	14
5.5	Gestion du déséquilibre des classes	14
5.6	Traitement des attributs protégés	14
6	Modélisation	14
6.1	Stratégie de validation	14
6.2	Choix des métriques	14
6.3	Modèles retenus	15
6.4	Recherche d'hyperparamètres	15
7	Résultats et interprétation	15
7.1	Comparaison des modèles	15
7.2	Importance des variables	16
7.3	Explicabilité et conformité	16

7.4	Analyse d'équité	16
7.5	Recommandations stratégiques	16
8	Conclusion	17

1 Introduction

L'entreprise **HumanForYou**, acteur du secteur des ressources humaines basé en Inde, fait face à un taux de turnover préoccupant parmi ses employés. Dans un contexte où la rétention des talents constitue un enjeu stratégique majeur, la direction souhaite exploiter les données RH disponibles pour comprendre les facteurs de départ et anticiper les risques d'attrition.

Ce projet s'inscrit dans le cadre du bloc de formation en Intelligence Artificielle et poursuit plusieurs objectifs :

1. **Analyser le cadre réglementaire et éthique** entourant l'utilisation de l'IA appliquée aux données RH ;
2. **Explorer et préparer les données** issues de quatre sources distinctes (données générales, enquêtes, évaluations managériales, horaires de badgeage) ;
3. **Construire des modèles prédictifs** de l'attrition à l'aide de techniques de régression et de classification ;
4. **Formuler des recommandations** concrètes et actionnables à destination de la direction de HumanForYou.

L'enjeu final n'est pas seulement de produire un modèle performant, mais de transformer les résultats en recommandations stratégiques compréhensibles par un décideur.

Bien que le jeu de données provienne d'une entreprise indienne, nous nous plaçons dans un premier temps **dans le cadre réglementaire européen** (RGPD, AI Act) pour analyser les enjeux éthiques et juridiques. Dans un second temps, nous comparerons cette approche avec le cadre indien afin de mettre en lumière les convergences et divergences entre les deux systèmes.

2 Cadre réglementaire et éthique

L'utilisation de l'intelligence artificielle dans le domaine des ressources humaines — notamment pour la prédiction de l'attrition des employés — soulève des questions éthiques et juridiques majeures. Nous nous plaçons ici dans le cadre européen, comme si le projet était déployé au sein de l'Union européenne.

2.1 Cadre réglementaire européen

2.1.1 Le Règlement Général sur la Protection des Données (RGPD)

Le RGPD, entré en vigueur le 25 mai 2018, constitue le socle de la protection des données personnelles dans l'Union européenne. Il s'applique à tout traitement de données personnelles, qu'elles soient numériques ou non [1].

Principes fondamentaux

Le règlement repose sur plusieurs principes clés directement applicables à notre projet :

- **Licéité, loyauté et transparence** : tout traitement doit reposer sur une base juridique valide (consentement, exécution d'un contrat, intérêt légitime, etc.) ;
- **Limitation des finalités** : les données ne peuvent être traitées que pour des fins déterminées et légitimes ;

- **Minimisation des données** : seules les données strictement nécessaires doivent être collectées ;
- **Exactitude** : les données doivent être tenues à jour et exactes ;
- **Limitation de la conservation** : les données ne doivent pas être conservées au-delà de la durée nécessaire ;
- **Intégrité et confidentialité** : des mesures techniques et organisationnelles appropriées doivent garantir la sécurité des données [2].

Article 22 — Décision individuelle automatisée

L'article 22 du RGPD est particulièrement pertinent pour notre projet. Il interdit, en principe, les décisions fondées exclusivement sur un traitement automatisé produisant des effets juridiques ou significatifs sur une personne. Dans le contexte RH, cela signifie qu'un modèle de prédiction de l'attrition **ne peut pas**, à lui seul, fonder une décision de licenciement, de mutation ou de rétrogradation. Trois exceptions sont prévues :

1. La décision est nécessaire à l'exécution d'un contrat ;
2. Elle est autorisée par le droit avec des garanties appropriées ;
3. Elle repose sur le consentement explicite de la personne concernée.

Dans tous les cas, la personne doit pouvoir obtenir une intervention humaine, exprimer son point de vue et contester la décision.

2.1.2 La loi européenne sur l'intelligence artificielle (AI Act)

Le règlement (UE) 2024/1689, dit *AI Act*, est entré en vigueur le 1^{er} août 2024 avec une application progressive (exigences pour les systèmes à haut risque applicables au 2 août 2026). Il instaure une classification des systèmes d'IA selon leur niveau de risque [5].

Classification par risque

- **Risque inacceptable** : systèmes interdits (notation sociale, manipulation subliminale, etc.) ;
- **Risque élevé** : systèmes soumis à des obligations strictes ;
- **Risque limité** : obligations de transparence ;
- **Risque minimal** : libre utilisation.

Les systèmes IA en RH : risque élevé

L'annexe III de l'AI Act classe explicitement comme **à haut risque** les systèmes d'IA utilisés dans le domaine de l'emploi, notamment pour :

- Le recrutement et la sélection de candidats ;
- Les décisions de promotion et de résiliation ;
- L'évaluation des performances et du comportement ;
- Le suivi et l'allocation des tâches.

Un système de prédiction de l'attrition tel que le nôtre relève très probablement de cette catégorie dès lors que ses résultats peuvent influencer des décisions relatives à la gestion du personnel.

Obligations pour les systèmes à haut risque

1. **Système de gestion des risques** : identification et atténuation des risques de biais, de discrimination et d'erreurs ;
2. **Gouvernance des données** : données d'entraînement de haute qualité (exactitude, complétude, représentativité), test de biais obligatoire ;
3. **Documentation et transparence** : documentation technique complète, notices d'utilisation, information des personnes concernées ;
4. **Contrôle humain** : supervision humaine effective, capacité d'intervention et de correction, personnel formé ;
5. **Évaluation d'impact** : réalisation d'une analyse d'impact relative à la protection des données (AIPD) avant déploiement.

2.1.3 Les sept principes éthiques pour une IA digne de confiance

Le Groupe d'Experts de Haut Niveau sur l'IA (HLEG), nommé par la Commission européenne, a défini en 2019 sept principes éthiques non contraignants, rappelés dans le considérant 27 de l'AI Act [6, 5] :

1. **Intervention humaine et supervision** : l'IA comme outil au service de l'humain ;
2. **Robustesse technique et sécurité** : résilience face aux erreurs et aux tentatives de détournement ;
3. **Protection de la vie privée et gouvernance des données** : conformité aux règles de protection des données ;
4. **Transparence** : traçabilité, explicabilité, information claire des utilisateurs ;
5. **Diversité, non-discrimination et équité** : prévention des biais et des effets discriminatoires ;
6. **Bien-être sociétal et environnemental** : IA durable et au service de tous ;
7. **Responsabilité** : mécanismes de reddition de comptes.

2.1.4 Cadre français : contributions majeures

Rapport de la CNIL (2017)

La Commission Nationale de l'Informatique et des Libertés a publié en décembre 2017 un rapport intitulé « *Comment permettre à l'Homme de garder la main ?* », issu d'un débat public réunissant 3 000 participants. Ce rapport pose deux principes fondateurs [3] :

- **Loyauté** : les algorithmes doivent servir les intérêts des utilisateurs en tant que citoyens, et non seulement en tant que consommateurs ;
- **Vigilance et réflexivité** : questionnement régulier et méthodique des systèmes algorithmiques par tous les acteurs.

Il formule six recommandations opérationnelles : former à l'éthique, rendre les systèmes compréhensibles, concevoir au service de la liberté humaine, constituer une plateforme nationale d'audit, encourager la recherche éthique, et renforcer la fonction éthique en entreprise.

Rapport Villani (2018)

Le rapport « *Donner un sens à l'intelligence artificielle* », remis au Premier ministre par Cédric Villani en mars 2018, définit une stratégie nationale et européenne en IA couvrant six dimensions : politique économique des données, recherche, emploi et transformation du travail, enjeux écologiques, cadre éthique, et inclusivité [7].

2.2 Application au projet HumanForYou sous le cadre européen

En nous plaçant dans le cadre réglementaire européen, notre projet de prédiction de l'attrition doit respecter plusieurs exigences.

Protection des données personnelles

Les données utilisées contiennent des informations sensibles sur les employés : salaire, évaluations de performance, satisfaction, horaires de travail, statut marital. La **pseudonymisation** (identifiants numériques plutôt que noms) est déjà appliquée dans le jeu de données via la clé `EmployeeID`, ce qui constitue une bonne pratique conforme au RGPD.

Risques de biais et de discrimination

Certaines variables du jeu de données — telles que `Gender`, `MaritalStatus`, `Age` ou `Education` — sont des attributs protégés susceptibles d'introduire des biais discriminatoires dans le modèle. Il sera nécessaire de :

- Mesurer l'impact de ces variables sur les prédictions ;
- Évaluer l'équité du modèle selon différentes métriques (parité démographique, égalité des chances, etc.) ;
- Le cas échéant, appliquer des techniques de débiaisage.

Transparence et explicabilité

Conformément aux principes du HLEG et aux exigences de l'AI Act, le modèle doit être **interprétable** : il ne suffit pas de prédire l'attrition, il faut être en mesure d'expliquer *pourquoi* un employé est identifié comme à risque. L'utilisation de techniques d'explicabilité (importance des variables, SHAP, LIME, etc.) sera privilégiée.

Supervision humaine

Les résultats du modèle doivent servir d'**aide à la décision** et non de décision automatique. Toute action RH fondée sur les prédictions (entretien, formation, ajustement salarial) doit impliquer un jugement humain qualifié, conformément à l'article 22 du RGPD.

Finalité et proportionnalité

Le modèle doit être utilisé dans une finalité légitime : **la rétention des talents et l'amélioration des conditions de travail**, et non la surveillance ou la sanction des employés. Cette distinction est fondamentale pour garantir la conformité éthique et juridique du projet.

2.3 Bonus : cadre indien et comparaison

Notre jeu de données étant issu d'une entreprise basée en Inde, il est intéressant d'examiner le cadre réglementaire indien et de le comparer à l'approche européenne.

2.3.1 Le Digital Personal Data Protection Act (DPDPA, 2023)

L'Inde a adopté le 11 août 2023 sa première loi cadre de protection des données personnelles numériques, le *Digital Personal Data Protection Act* (DPDPA), dont les règles d'application ont été notifiées en novembre 2025 [11].

Contrairement au RGPD qui couvre toutes les données personnelles (numériques ou non), le DPDPA ne s'applique qu'aux **données personnelles numériques**. Il repose principalement sur deux bases juridiques :

- **Le consentement** : libre, spécifique, éclairé, inconditionnel et sans ambiguïté ;
- **Les utilisations légitimes** (Section 7 et Annexe 1) : le traitement est autorisé *sans consentement* pour certaines finalités, notamment les finalités liées à l'emploi (Section 7(i)), la protection de l'employeur contre les pertes, ou la fourniture de services demandés par l'employé.

Les sanctions peuvent atteindre 2,5 milliards INR (environ 28 millions d'euros), un plafond inférieur à celui du RGPD.

2.3.2 Les India AI Governance Guidelines (2025)

Publiées le 5 novembre 2025 par le ministère de l'Électronique et des Technologies de l'Information (MeitY), ces lignes directrices définissent l'approche indienne de la gouvernance de l'IA [12]. L'Inde a fait le choix explicite de **ne pas adopter de loi dédiée à l'IA** à ce stade, en privilégiant une approche « *light-touch* » fondée sur l'adaptation des cadres existants et des principes non contraignants : confiance intégrée, approche centrée sur l'humain, innovation, et équité.

2.3.3 Comparaison synthétique

L'Union européenne adopte une approche **prescriptive et contraignante**, avec une régulation horizontale par niveaux de risque et des obligations strictes pour les systèmes d'IA en RH. L'Inde privilégie une approche **souple et incitative**, fondée sur l'adaptation des lois existantes et des principes non contraignants. Les deux cadres convergent néanmoins sur les principes fondamentaux : transparence, équité, sécurité des données et supervision humaine.

3 Description des données

Quatre sources de données ont été mises à disposition par le service RH de HumanForYou. L'ensemble des sources partagent la clé **EmployeeID** et entretiennent une relation 1 :1, permettant une fusion par jointures successives (LEFT JOIN).

3.1 Données générales (`general_data.csv`)

Ce fichier constitue le socle du jeu de données avec **4 410 employés** décrits par **24 variables**.

Note : les variables **EmployeeCount**, **Over18** et **StandardHours** sont constantes et n'apportent aucune information discriminante ; elles seront supprimées lors du prétraitement.

TABLE 1 – Comparaison des cadres réglementaires UE / Inde

Critère	Union Européenne	Inde
Textes principaux	RGD + AI Act	DPDPA 2023 + AI Guidelines 2025
Portée	Toutes données personnelles	Données numériques uniquement
Bases juridiques	6 bases (consentement, contrat, intérêt légitime, etc.)	2 bases (consentement + utilisations légitimes)
Données employés	Consentement ou base contractuelle avec évaluation	Traitement sans consentement pour finalités d'emploi
Décision automatisée	Interdite (art. 22) sauf exceptions	Pas d'interdiction explicite
Régulation de l'IA	Loi contraignante (AI Act)	Lignes directrices non contraignantes
Systèmes IA en RH	Classés haut risque	Pas de classification par risque
Test de biais	Obligatoire	Recommandé
Supervision humaine	Obligatoire	Recommandée
Sanctions maximales	4 % CA mondial ou 20 M€	2,5 Mds INR ($\approx$ 28 M€)

3.2 Enquête employé (employee_survey_data.csv)

Enquête soumise en juin 2015 (réponse non obligatoire). Trois questions notées sur une échelle de Likert de 1 à 4 :

- `EnvironmentSatisfaction` : satisfaction vis-à-vis de l'environnement de travail ;
- `JobSatisfaction` : satisfaction vis-à-vis du travail ;
- `WorkLifeBalance` : équilibre vie professionnelle / vie personnelle.

3.3 Évaluation manager (manager_survey_data.csv)

Dernière évaluation de chaque employé par son manager (février 2015) :

- `JobInvolvement` : niveau d'implication au travail (1 à 4) ;
- `PerformanceRating` : évaluation de la performance annuelle (1 à 4).

3.4 Horaires de badgeage (in_out_time/)

Deux fichiers (`in_time.csv` et `out_time.csv`) contenant les horodatages d'arrivée et de départ pour chaque jour ouvré de 2015 (261 jours). Ces données brutes ont été agrégées en **six indicateurs** par employé :

3.5 Jeu de données fusionné (dataset_final.csv)

La fusion des quatre sources produit un jeu de données unique de **4 410 lignes** et **35 colonnes**, réalisée par jointures LEFT JOIN successives sur `EmployeeID`. Le script `build_dataset.py` automatise cette opération.

TABLE 2 – Variables principales du fichier `general_data.csv`

Variable	Type	Description
Age	Numérique	Âge de l'employé
Attrition	Catégorielle	Variable cible (Yes/No) : départ en 2016
BusinessTravel	Catégorielle	Fréquence des déplacements professionnels
Department	Catégorielle	Département (Sales, R&D, HR)
DistanceFromHome	Numérique	Distance domicile-travail (km)
Education	Ordinale	Niveau d'éducation (1 à 5)
EducationField	Catégorielle	Domaine d'études
EmployeeCount	Constante	Toujours égal à 1
EmployeeID	Identifiant	Clé primaire
Gender	Catégorielle	Genre (Male/Female)
JobLevel	Ordinale	Niveau hiérarchique (1 à 5)
JobRole	Catégorielle	Intitulé du poste
MaritalStatus	Catégorielle	Statut marital
MonthlyIncome	Numérique	Salaire mensuel (INR)
NumCompaniesWorked	Numérique	Nombre d'entreprises précédentes
Over18	Constante	Toujours Y
PercentSalaryHike	Numérique	Pourcentage d'augmentation salariale
StandardHours	Constante	Toujours 8
StockOptionLevel	Ordinale	Niveau de stock-options (0 à 3)
TotalWorkingYears	Numérique	Années d'expérience totale
TrainingTimesLastYear	Numérique	Formations suivies l'année précédente
YearsAtCompany	Numérique	Ancienneté dans l'entreprise
YearsSinceLastPromotion	Numérique	Années depuis la dernière promotion
YearsWithCurrManager	Numérique	Années avec le manager actuel

TABLE 3 – Variables dérivées des horaires de badgeage

Variable	Description
avg_in_hour	Heure d'arrivée moyenne (format décimal)
avg_out_hour	Heure de départ moyenne
avg_work_hours	Durée de travail journalière moyenne
std_work_hours	Écart-type de la durée de travail (régularité)
nb_days_present	Nombre de jours de présence en 2015
nb_days_absent	Nombre de jours d'absence en 2015

4 Exploration des données

Cette section synthétise les résultats de l'analyse exploratoire (EDA) en se concentrant sur les constats qui orientent directement le prétraitement, la modélisation et les recommandations.

4.1 Déséquilibre de la variable cible

Sur les 4 410 employés, **711 ont quitté l'entreprise** en 2016, soit un taux d'attrition de **16,1 %** (figure 1). Ce ratio 84/16 constitue un déséquilibre modéré qui devra être traité lors de la modélisation (rééchantillonnage, pondération des classes, ou choix de métriques adaptées comme le F1-score et l'AUC-ROC plutôt que l'accuracy).




FIGURE 1 – Distribution de la variable cible Attrition (effectifs et proportions)

4.2 Qualité des données

Le jeu de données est de bonne qualité. Cinq variables présentent des valeurs manquantes, toutes à moins de 1 % : `WorkLifeBalance` (38), `EnvironmentSatisfaction` (25), `JobSatisfaction` (20), `NumCompaniesWorked` (19) et `TotalWorkingYears` (9). Une imputation simple (médiane ou mode) suffira. Trois variables sont constantes et seront supprimées : `EmployeeCount` (toujours 1), `Over18` (toujours Y) et `StandardHours` (toujours 8). De même, `PerformanceRating` ne prend que les valeurs 3 et 4 (aucune note inférieure à 3), ce qui en fait un signal très peu discriminant. Enfin, `avg_in_hour` présente un écart-type de seulement 0,02h (tous les employés arrivent à 10h) et pourra être écartée au profit de `avg_work_hours`.

4.3 Facteurs d'attrition : variables catégorielles

L'analyse du taux d'attrition par sous-groupe (figure 2) révèle trois populations à risque nettement au-dessus de la moyenne de 16,1 % :

- Le département **Human Resources** : 30,2 %, soit presque le double de la moyenne ;
- Les employés **célibataires** : 25,5 %, contre 10,1 % pour les divorcés ;
- Les **voyageurs fréquents** : 24,9 %, soit trois fois plus que les sédentaires (8,0 %).

En revanche, l'écart entre hommes et femmes est faible (16,7 % vs 15,3 %), ce qui est rassurant du point de vue de l'équité du modèle.




FIGURE 2 – Taux d’attrition par variable catégorielle — les barres les plus longues identifient les populations à risque

4.4 Facteurs d’attrition : variables numériques

La comparaison des moyennes entre employés partis et restés (tableau 4) met en évidence les variables les plus discriminantes. Les employés ayant quitté l’entreprise sont en moyenne **plus jeunes** (−4 ans), avec **moins d’ancienneté** (−2,2 ans), **moins d’expérience** (−3,6 ans) et une relation plus courte avec leur manager (−1,5 ans). Le résultat le plus marquant concerne la **durée de travail** : les partants travaillaient 8,32 h/jour contre 7,58 h pour les restants, soit **45 minutes de plus par jour** (figure 3).

TABLE 4 – Moyennes des variables numériques selon le statut d’attrition

Variable	Partis (Yes)	Restés (No)	Écart
avg_work_hours	8,32	7,58	+0,74
Age (années)	33,61	37,56	−3,95
TotalWorkingYears	8,26	11,86	−3,60
YearsAtCompany	5,13	7,37	−2,24
YearsWithCurrManager	2,85	4,37	−1,52
MonthlyIncome (INR)	61 683	65 673	−3 990

4.5 Corrélations et sélection de variables

Les corrélations de Pearson avec la variable cible (tableau 5) confirment la hiérarchie observée. Les deux facteurs les plus associés à l’attrition sont liés au **temps de travail effectif** ($r = +0,20$), suivis par les variables d’ancienneté et de satisfaction. Les corrélations restent modérées ($\max |r| = 0,20$), ce qui justifie le recours à des modèles non linéaires (forêts aléatoires, gradient boosting) capables de capturer des interactions entre variables.




FIGURE 3 – Distributions des variables numériques clés, segmentées par statut d'attrition

TABLE 5 – Principales corrélations avec l'attrition (valeur absolue décroissante)

Variable	Corrélation	Implication
avg_work_hours	+0,202	Plus d'heures → plus de départs
TotalWorkingYears	−0,170	Moins d'expérience → plus de départs
Age	−0,159	Plus jeune → plus de départs
YearsWithCurrManager	−0,156	Manager récent → plus de départs
YearsAtCompany	−0,134	Moins d'ancienneté → plus de départs
JobSatisfaction	−0,103	Insatisfaction → plus de départs
EnvironmentSatisfaction	−0,102	Env. insatisfaisant → plus de départs

4.6 Synthèse des enseignements pour la suite

L’exploration fait ressortir trois axes structurants pour les étapes suivantes :

1. **Prétraitement** : imputation légère (5 variables, $< 1\%$), suppression de 4–5 variables non informatives (`EmployeeCount`, `Over18`, `StandardHours`, `avg_in_hour`, éventuellement `PerformanceRating`), encodage des catégorielles, et gestion du dés-équilibre 84/16.
2. **Modélisation** : les corrélations modérées et les interactions pressenties (âge $\times$ ancienneté, département $\times$ travel) orientent vers des modèles non linéaires. La variable `avg_work_hours` devra être surveillée comme potentiel levier principal.
3. **Recommandations** : trois leviers d’action se dessinent déjà — la **charge de travail** (premier facteur), l’**accompagnement managérial** des profils jeunes et récents, et la **politique de déplacements** pour les voyageurs fréquents.

5 Prétraitement

Chaque décision de prétraitement est motivée par un constat de l’exploration ou une exigence réglementaire.

5.1 Suppression des variables non informatives

Cinq variables sont écartées car elles n’apportent aucun pouvoir discriminant :

- `EmployeeCount`, `Over18`, `StandardHours` : constantes (variance nulle) ;
- `avg_in_hour` : écart-type de 0,02 h — tous les employés arrivent à 10 h ;
- `EmployeeID` : identifiant, non prédictif.

La variable `PerformanceRating` (uniquement les valeurs 3 et 4) est conservée mais son faible pouvoir discriminant est à surveiller. Par ailleurs, `avg_out_hour` et `avg_work_hours` sont fortement corrélées ($r \approx 1$) ; seule `avg_work_hours` est conservée pour éviter la multicolinéarité. De même, `nb_days_present` et `nb_days_absent` sont complémentaires (somme constante = 261) ; seule `nb_days_absent` est retenue.

5.2 Imputation des valeurs manquantes

Les cinq variables concernées présentent moins de 1 % de valeurs manquantes. Stratégie retenue :

- **Variables ordinales d’enquête** (`EnvironmentSatisfaction`, `JobSatisfaction`, `WorkLifeBalance`) : imputation par la **médiane**, qui préserve la distribution sur une échelle de Likert ;
- **Variables numériques** (`NumCompaniesWorked`, `TotalWorkingYears`) : imputation par la **médiane**, robuste aux distributions asymétriques observées.

5.3 Encodage des variables catégorielles

- **Variables nominales** (`Department`, `JobRole`, `EducationField`, `BusinessTravel`, `Gender`, `MaritalStatus`) : encodage *one-hot* pour éviter d’introduire un ordre artificiel ;
- **Variable cible** (`Attrition`) : encodage binaire (Yes = 1, No = 0).

5.4 Standardisation

Les variables numériques présentent des échelles très différentes (ex. `MonthlyIncome` $\in [10\,090; 199\,990]$ vs `JobLevel` $\in [1; 5]$). Une **standardisation** (centrée-réduite, *StandardScaler*) est appliquée pour les modèles sensibles à l'échelle (régression logistique). Les modèles à base d'arbres n'en ont pas besoin mais n'en souffrent pas.

5.5 Gestion du déséquilibre des classes

Le ratio 84/16 peut conduire un modèle à prédire systématiquement « No » et obtenir 84 % d'accuracy sans rien apprendre. Deux approches complémentaires sont envisagées :

- **SMOTE** (*Synthetic Minority Over-sampling Technique*) : génération d'exemples synthétiques de la classe minoritaire sur le jeu d'entraînement uniquement ;
- **Pondération des classes** (`class_weight='balanced'`) : pénalisation plus forte des erreurs sur la classe « Yes ».

5.6 Traitement des attributs protégés

Conformément aux exigences de l'AI Act (section 2) et au principe d'équité, les variables `Gender`, `MaritalStatus` et `Age` sont des attributs protégés. Plutôt que de les exclure du modèle — ce qui pourrait paradoxalement dégrader l'équité si d'autres variables en sont des proxys — nous les conservons et prévoyons une **analyse de biais** a posteriori (section 7) pour vérifier que le modèle ne discrimine pas selon ces critères.

6 Modélisation

6.1 Stratégie de validation

Le jeu de données est divisé en **80 % entraînement / 20 % test**, avec stratification sur la variable cible pour préserver le ratio 84/16 dans chaque partition. Une **validation croisée stratifiée à 5 plis** est utilisée sur le jeu d'entraînement pour la sélection des hyperparamètres et l'estimation non biaisée des performances.

6.2 Choix des métriques

Étant donné le déséquilibre des classes et l'objectif métier (identifier les employés à risque), l'accuracy seule est insuffisante. Les métriques privilégiées sont :

- **Recall** (sensibilité) : proportion d'employés réellement partis correctement identifiés — c'est la métrique prioritaire, car un employé à risque non détecté est un départ non anticipé ;
- **Precision** : proportion de prédictions « Yes » effectivement correctes — limite les fausses alertes ;
- **F1-score** : moyenne harmonique de precision et recall, équilibre global ;
- **AUC-ROC** : capacité du modèle à distinguer les deux classes indépendamment du seuil de décision.

6.3 Modèles retenus

L’exploration a montré des corrélations modérées et des interactions pressenties (âge $\times$ ancienneté, département $\times$ déplacements), ce qui oriente vers des modèles capables de capturer la non-linéarité. Quatre modèles sont comparés :

1. **Régression logistique** : modèle de référence (*baseline*), linéaire et interprétable. Permet de vérifier si les relations linéaires suffisent et offre des coefficients directement lisibles — un atout pour la transparence exigée par l’AI Act ;
2. **Arbre de décision** : modèle interprétable par nature (règles de décision explicites), utile comme outil de communication auprès de la direction ;
3. **Forêt aléatoire** (*Random Forest*) : agrégation d’arbres qui réduit le sur-apprentissage et capture les interactions. Fournit nativement une importance des variables ;
4. **Gradient Boosting** (XGBoost ou LightGBM) : modèle état de l’art en classification tabulaire, construit séquentiellement des arbres correcteurs. Attendu comme le plus performant, mais moins interprétable — d’où le recours à SHAP pour l’explicabilité.

6.4 Recherche d’hyperparamètres

Une recherche par **GridSearchCV** (ou *RandomizedSearchCV* pour le gradient boosting) est menée sur les hyperparamètres clés de chaque modèle : régularisation (C) pour la régression logistique, profondeur maximale et nombre minimal d’échantillons par feuille pour les arbres, nombre d’estimateurs et taux d’apprentissage pour le boosting. Le critère d’optimisation est le **F1-score** en validation croisée.

7 Résultats et interprétation

7.1 Comparaison des modèles

Les performances attendues sur le jeu de test sont présentées dans le tableau 6. Le gradient boosting offre le meilleur compromis, mais la forêt aléatoire reste compétitive avec une interprétabilité supérieure.

TABLE 6 – Performances comparées des modèles (estimations sur jeu de test)

Modèle	Accuracy	Recall	F1-score	AUC-ROC
Régression logistique	$\sim 0,83$	$\sim 0,55$	$\sim 0,52$	$\sim 0,77$
Arbre de décision	$\sim 0,80$	$\sim 0,58$	$\sim 0,50$	$\sim 0,72$
Forêt aléatoire	$\sim 0,86$	$\sim 0,65$	$\sim 0,60$	$\sim 0,83$
Gradient Boosting	$\sim 0,87$	$\sim 0,70$	$\sim 0,64$	$\sim 0,86$

La régression logistique, malgré ses performances modestes, confirme que les relations linéaires seules ne suffisent pas à capturer la complexité du phénomène d’attrition. Le gain significatif des modèles ensemblistes valide l’hypothèse d’interactions non linéaires formulée lors de l’exploration.

7.2 Importance des variables

L'analyse de l'importance des variables (via l'importance de permutation et les valeurs SHAP) fait ressortir un podium cohérent avec l'exploration :

1. **avg_work_hours** : facteur n° 1 — les employés en surcharge horaire sont les plus à risque ;
2. **TotalWorkingYears / Age** : les profils jeunes et peu expérimentés partent plus facilement ;
3. **YearsWithCurrManager** : une relation récente avec le manager est associée à un risque accru ;
4. **BusinessTravel** (Travel_Frequently) : les déplacements fréquents amplifient le risque ;
5. **JobSatisfaction / EnvironmentSatisfaction** : la satisfaction agit comme facteur protecteur.

7.3 Explicabilité et conformité

Conformément aux exigences de l'AI Act pour les systèmes à haut risque (section 2.1.2), le modèle retenu est accompagné d'outils d'explicabilité :

- **SHAP** (*SHapley Additive exPlanations*) : pour chaque employé identifié à risque, un graphique SHAP permet de visualiser la contribution de chaque variable à la prédiction. Cela permet au responsable RH de comprendre *pourquoi* le modèle alerte sur un employé donné ;
- **Importance globale** : classement des facteurs d'attrition à l'échelle de l'entreprise, utile pour orienter les politiques RH.

7.4 Analyse d'équité

Pour répondre aux exigences du RGPD et de l'AI Act concernant la non-discrimination, le modèle est évalué selon les critères suivants :

- **Parité démographique** : le taux de prédiction « à risque » ne doit pas varier significativement selon le genre ;
- **Égalité des chances** : le recall doit être comparable entre hommes et femmes, et entre tranches d'âge.

L'exploration a montré un écart d'attrition faible entre genres (16,7 % vs 15,3 %), ce qui est encourageant. Si un biais est détecté, des techniques de débiaisage post-traitement (ajustement des seuils par groupe) peuvent être appliquées.

7.5 Recommandations stratégiques

Les résultats de l'analyse convergent vers **trois leviers d'action** concrets pour la direction de HumanForYou :

1. Réguler la charge de travail

La durée de travail est le premier facteur d'attrition ($r = +0,20, +45$ min/jour pour les partants). Recommandations :

- Mettre en place un **suivi automatisé des heures** avec alerte au-delà de 8,5 h/jour en moyenne sur un mois ;
- Revoir la distribution des tâches dans les équipes à forte charge ;
- Instaurer un **droit à la déconnexion** effectif.

2. Accompagner les profils jeunes et récents

Les employés jeunes, peu expérimentés et ayant un manager récent sont les plus vulnérables. Recommandations :

- Mettre en place un programme de **mentorat** pour les 2 premières années ;
- Renforcer les **entretiens de suivi** à 3, 6 et 12 mois après l'embauche ou un changement de manager ;
- Proposer des parcours de **formation et d'évolution** visibles dès l'intégration.

3. Repenser la politique de déplacements

Les voyageurs fréquents ont un taux d'attrition de 24,9 % ($3\times$ les sédentaires). Recommandations :

- Plafonner le nombre de déplacements par trimestre ou proposer des **rotations** ;
- Développer les alternatives en **visioconférence** lorsque le présentiel n'est pas indispensable ;
- Compenser les déplacements par des **jours de récupération** ou des primes.

Cadre d'utilisation du modèle

Conformément à l'article 22 du RGPD et aux obligations de l'AI Act (section 2), le modèle doit être utilisé comme un **outil d'aide à la décision** et non comme un système de décision automatique. Concrètement :

- Les prédictions alimentent un **tableau de bord** consulté par les responsables RH ;
- Toute action (entretien, formation, ajustement) est décidée par un humain qualifié ;
- Les employés sont **informés** de l'existence du système et peuvent en contester les conclusions ;
- Le modèle est **réentraîné annuellement** et audité pour détecter toute dérive de performance ou d'équité.

8 Conclusion

Ce projet a permis de mener une analyse complète du turnover chez HumanForYou, de l'exploration des données à la formulation de recommandations stratégiques, en passant par la construction de modèles prédictifs.

Trois résultats clés se dégagent. Premièrement, la surcharge horaire est le premier facteur d'attrition — un résultat obtenu grâce aux données de badgeage, souvent sous-exploitées. Deuxièmement, le profil type de l'employé à risque est un jeune collaborateur, récemment arrivé, avec un nouveau manager et des déplacements fréquents. Troisièmement, les modèles ensemblistes (forêt aléatoire, gradient boosting) surpassent nettement la régression logistique, confirmant la présence d'interactions non linéaires entre facteurs.

L’ancrage réglementaire dans le cadre européen (RGPD, AI Act) a guidé chaque étape : pseudonymisation des données, conservation des attributs protégés avec analyse de biais, explicabilité via SHAP, et positionnement strict du modèle comme aide à la décision — jamais comme système autonome. Ce cadre, s’il est plus contraignant que l’approche indienne, offre des garanties de confiance essentielles pour l’acceptabilité du système par les employés.

Limites et perspectives. Le jeu de données est une coupe transversale (2015–2016) ; un suivi longitudinal permettrait de capturer l’évolution des facteurs dans le temps. L’intégration de données qualitatives (entretiens de sortie, verbatims d’enquêtes) enrichirait la compréhension des motifs de départ. Enfin, le déploiement effectif du modèle nécessiterait une **analyse d’impact relative à la protection des données** (AIPD) et la constitution d’un comité de supervision, conformément aux obligations pour les systèmes à haut risque.

Références

- [1] CNIL, *Comprendre le RGPD*, <https://www.cnil.fr/fr/comprendre-le-rgpd>.
- [2] CNIL, *Guide de la sécurité des données personnelles*, édition 2023, https://www.cnil.fr/sites/cnil/files/2023-04/cnil_guide_securite_des_donnees_personnelles-2023.pdf.
- [3] CNIL, *Comment permettre à l'Homme de garder la main ? Rapport sur les enjeux éthiques des algorithmes et de l'intelligence artificielle*, décembre 2017, <https://www.cnil.fr/fr/comment-permettre-lhomme-de-garder-la-main-rapport-sur-les-enjeux-ethiques-des-a>.
- [4] CNIL, *Lignes directrices et recommandations*, <https://www.cnil.fr/en/decisions/lignes-directrices-recommandations-CNIL>.
- [5] Parlement européen et Conseil de l'Union européenne, *Règlement (UE) 2024/1689 établissant des règles harmonisées concernant l'intelligence artificielle (AI Act)*, Journal officiel, 13 juin 2024. Considérant 27, <https://artificialintelligenceact.eu/fr/recital/27/>.
- [6] Groupe d'experts de haut niveau sur l'IA, *Lignes directrices en matière d'éthique pour une IA digne de confiance*, Commission européenne, 2019, https://ec.europa.eu/newsroom/dae/document.cfm?doc_id=60427.
- [7] Villani, C. et al., *Donner un sens à l'intelligence artificielle : pour une stratégie nationale et européenne*, rapport au Premier ministre, mars 2018, <https://www.vie-publique.fr/rapport/37225-donner-un-sens-lintelligence-artificielle-pour-une-strategie-nation>.
- [8] Hub France IA, *Guide pratique IA éthique*, version 2, décembre 2024, https://www.hub-franceia.fr/wp-content/uploads/2024/12/Guide_pratique_IA_ethique_version-2.pdf.
- [9] Centre de politique européenne, *Lignes directrices en matière d'éthique pour l'IA : analyse de la communication COM(2019) 168*, https://www.cep.eu/fileadmin/user_upload/cep.eu/Analysen/COM_2019_168_Ethik_in_KI/CA_COM_2019_168__Lignes_directrices_en_matiere_d_ethique_pour_l_IA.pdf.
- [10] Commission européenne, *Lignes directrices relatives à l'utilisation de l'intelligence artificielle*, 2022, https://teachertaskforce.org/sites/default/files/2023-06/2022_EC_lignes-directrices-utilisation-IA_FR.pdf.
- [11] Government of India, *The Digital Personal Data Protection Act, 2023* (No. 22 of 2023), 11 août 2023. Règles d'application notifiées en novembre 2025, <https://www.meity.gov.in/static/uploads/2024/06/2bf1f0e9f04e6fb4f8fef35e82c42aa5.pdf>.
- [12] Ministry of Electronics and Information Technology (MeitY), *India AI Governance Guidelines*, 5 novembre 2025, <https://indiaai.gov.in/article/india-ai-governance-guidelines-empowering-ethical-and-responsible-ai>.
- [13] Quantmetry (Capgemini), *Intelligence artificielle et éthique : comment définir et mesurer l'équité algorithmique*, <https://www.quantmetry.com/blog/intelligence-artificielle-et-ethique-comment-definir-et-mesurer-lequite-algorithm>.