

Projet Bloc IA

Analyse du turnover chez HumanForYou

Maxence Chartier

Amine Haouri

Anisse Imerzoukene

Mourad Messaoudi

26 mars 2026

Table des matières

1	Introduction	3
2	Cadre réglementaire et éthique	3
2.1	Cadre réglementaire européen	3
2.1.1	Le Règlement Général sur la Protection des Données (RGPD) . . .	3
2.1.2	La loi européenne sur l'intelligence artificielle (AI Act)	4
2.1.3	Les sept principes éthiques pour une IA digne de confiance	5
2.1.4	Cadre français : contributions majeures	5
2.2	Application au projet HumanForYou sous le cadre européen	6
2.3	Bonus : cadre indien et comparaison	6
2.3.1	Le Digital Personal Data Protection Act (DPDPA, 2023)	7
2.3.2	Les India AI Governance Guidelines (2025)	7
2.3.3	Comparaison synthétique	7
3	Description des données	7
3.1	Données générales (<code>general_data.csv</code>)	7
3.2	Enquête employé (<code>employee_survey_data.csv</code>)	8
3.3	Évaluation manager (<code>manager_survey_data.csv</code>)	8
3.4	Horaires de badgeage (<code>in_out_time/</code>)	8
3.5	Jeu de données fusionné (<code>dataset_final.csv</code>)	8
4	Exploration des données	10
4.1	Variable cible : Attrition	10
4.2	Valeurs manquantes	10
4.3	Statistiques descriptives des variables numériques	10
4.4	Variables d'enquête et d'évaluation	12
4.5	Indicateurs issus des horaires de badgeage	12
4.6	Répartition des variables catégorielles	15
4.7	Taux d'attrition par catégorie	15
4.8	Comparaison des moyennes selon l'attrition	16
4.9	Corrélations avec l'attrition	16
4.10	Variables à variance nulle	17
5	Prétraitement	17
6	Modélisation	17
7	Résultats et interprétation	17
8	Conclusion	17

1 Introduction

L'entreprise **HumanForYou**, acteur du secteur des ressources humaines basé en Inde, fait face à un taux de turnover préoccupant parmi ses employés. Dans un contexte où la rétention des talents constitue un enjeu stratégique majeur, la direction souhaite exploiter les données RH disponibles pour comprendre les facteurs de départ et anticiper les risques d'attrition.

Ce projet s'inscrit dans le cadre du bloc de formation en Intelligence Artificielle et poursuit plusieurs objectifs :

1. **Analyser le cadre réglementaire et éthique** entourant l'utilisation de l'IA appliquée aux données RH ;
2. **Explorer et préparer les données** issues de quatre sources distinctes (données générales, enquêtes, évaluations managériales, horaires de badgeage) ;
3. **Construire des modèles prédictifs** de l'attrition à l'aide de techniques de régression et de classification ;
4. **Formuler des recommandations** concrètes et actionnables à destination de la direction de HumanForYou.

L'enjeu final n'est pas seulement de produire un modèle performant, mais de transformer les résultats en recommandations stratégiques compréhensibles par un décideur.

Bien que le jeu de données provienne d'une entreprise indienne, nous nous plaçons dans un premier temps **dans le cadre réglementaire européen** (RGPD, AI Act) pour analyser les enjeux éthiques et juridiques. Dans un second temps, nous comparerons cette approche avec le cadre indien afin de mettre en lumière les convergences et divergences entre les deux systèmes.

2 Cadre réglementaire et éthique

L'utilisation de l'intelligence artificielle dans le domaine des ressources humaines — notamment pour la prédiction de l'attrition des employés — soulève des questions éthiques et juridiques majeures. Nous nous plaçons ici dans le cadre européen, comme si le projet était déployé au sein de l'Union européenne.

2.1 Cadre réglementaire européen

2.1.1 Le Règlement Général sur la Protection des Données (RGPD)

Le RGPD, entré en vigueur le 25 mai 2018, constitue le socle de la protection des données personnelles dans l'Union européenne. Il s'applique à tout traitement de données personnelles, qu'elles soient numériques ou non [1].

Principes fondamentaux

Le règlement repose sur plusieurs principes clés directement applicables à notre projet :

- **Licéité, loyauté et transparence** : tout traitement doit reposer sur une base juridique valide (consentement, exécution d'un contrat, intérêt légitime, etc.) ;
- **Limitation des finalités** : les données ne peuvent être traitées que pour des fins déterminées et légitimes ;

- **Minimisation des données** : seules les données strictement nécessaires doivent être collectées ;
- **Exactitude** : les données doivent être tenues à jour et exactes ;
- **Limitation de la conservation** : les données ne doivent pas être conservées au-delà de la durée nécessaire ;
- **Intégrité et confidentialité** : des mesures techniques et organisationnelles appropriées doivent garantir la sécurité des données [2].

Article 22 — Décision individuelle automatisée

L'article 22 du RGPD est particulièrement pertinent pour notre projet. Il interdit, en principe, les décisions fondées exclusivement sur un traitement automatisé produisant des effets juridiques ou significatifs sur une personne. Dans le contexte RH, cela signifie qu'un modèle de prédiction de l'attrition **ne peut pas**, à lui seul, fonder une décision de licenciement, de mutation ou de rétrogradation. Trois exceptions sont prévues :

1. La décision est nécessaire à l'exécution d'un contrat ;
2. Elle est autorisée par le droit avec des garanties appropriées ;
3. Elle repose sur le consentement explicite de la personne concernée.

Dans tous les cas, la personne doit pouvoir obtenir une intervention humaine, exprimer son point de vue et contester la décision.

2.1.2 La loi européenne sur l'intelligence artificielle (AI Act)

Le règlement (UE) 2024/1689, dit *AI Act*, est entré en vigueur le 1^{er} août 2024 avec une application progressive (exigences pour les systèmes à haut risque applicables au 2 août 2026). Il instaure une classification des systèmes d'IA selon leur niveau de risque [5].

Classification par risque

- **Risque inacceptable** : systèmes interdits (notation sociale, manipulation subliminale, etc.) ;
- **Risque élevé** : systèmes soumis à des obligations strictes ;
- **Risque limité** : obligations de transparence ;
- **Risque minimal** : libre utilisation.

Les systèmes IA en RH : risque élevé

L'annexe III de l'AI Act classe explicitement comme **à haut risque** les systèmes d'IA utilisés dans le domaine de l'emploi, notamment pour :

- Le recrutement et la sélection de candidats ;
- Les décisions de promotion et de résiliation ;
- L'évaluation des performances et du comportement ;
- Le suivi et l'allocation des tâches.

Un système de prédiction de l'attrition tel que le nôtre relève très probablement de cette catégorie dès lors que ses résultats peuvent influencer des décisions relatives à la gestion du personnel.

Obligations pour les systèmes à haut risque

1. **Système de gestion des risques** : identification et atténuation des risques de biais, de discrimination et d'erreurs ;
2. **Gouvernance des données** : données d'entraînement de haute qualité (exactitude, complétude, représentativité), test de biais obligatoire ;
3. **Documentation et transparence** : documentation technique complète, notices d'utilisation, information des personnes concernées ;
4. **Contrôle humain** : supervision humaine effective, capacité d'intervention et de correction, personnel formé ;
5. **Évaluation d'impact** : réalisation d'une analyse d'impact relative à la protection des données (AIPD) avant déploiement.

2.1.3 Les sept principes éthiques pour une IA digne de confiance

Le Groupe d'Experts de Haut Niveau sur l'IA (HLEG), nommé par la Commission européenne, a défini en 2019 sept principes éthiques non contraignants, rappelés dans le considérant 27 de l'AI Act [6, 5] :

1. **Intervention humaine et supervision** : l'IA comme outil au service de l'humain ;
2. **Robustesse technique et sécurité** : résilience face aux erreurs et aux tentatives de détournement ;
3. **Protection de la vie privée et gouvernance des données** : conformité aux règles de protection des données ;
4. **Transparence** : traçabilité, explicabilité, information claire des utilisateurs ;
5. **Diversité, non-discrimination et équité** : prévention des biais et des effets discriminatoires ;
6. **Bien-être sociétal et environnemental** : IA durable et au service de tous ;
7. **Responsabilité** : mécanismes de reddition de comptes.

2.1.4 Cadre français : contributions majeures

Rapport de la CNIL (2017)

La Commission Nationale de l'Informatique et des Libertés a publié en décembre 2017 un rapport intitulé « *Comment permettre à l'Homme de garder la main ?* », issu d'un débat public réunissant 3 000 participants. Ce rapport pose deux principes fondateurs [3] :

- **Loyauté** : les algorithmes doivent servir les intérêts des utilisateurs en tant que citoyens, et non seulement en tant que consommateurs ;
- **Vigilance et réflexivité** : questionnement régulier et méthodique des systèmes algorithmiques par tous les acteurs.

Il formule six recommandations opérationnelles : former à l'éthique, rendre les systèmes compréhensibles, concevoir au service de la liberté humaine, constituer une plateforme nationale d'audit, encourager la recherche éthique, et renforcer la fonction éthique en entreprise.

Rapport Villani (2018)

Le rapport « *Donner un sens à l'intelligence artificielle* », remis au Premier ministre par Cédric Villani en mars 2018, définit une stratégie nationale et européenne en IA couvrant six dimensions : politique économique des données, recherche, emploi et transformation du travail, enjeux écologiques, cadre éthique, et inclusivité [7].

2.2 Application au projet HumanForYou sous le cadre européen

En nous plaçant dans le cadre réglementaire européen, notre projet de prédiction de l'attrition doit respecter plusieurs exigences.

Protection des données personnelles

Les données utilisées contiennent des informations sensibles sur les employés : salaire, évaluations de performance, satisfaction, horaires de travail, statut marital. La **pseudonymisation** (identifiants numériques plutôt que noms) est déjà appliquée dans le jeu de données via la clé `EmployeeID`, ce qui constitue une bonne pratique conforme au RGPD.

Risques de biais et de discrimination

Certaines variables du jeu de données — telles que `Gender`, `MaritalStatus`, `Age` ou `Education` — sont des attributs protégés susceptibles d'introduire des biais discriminatoires dans le modèle. Il sera nécessaire de :

- Mesurer l'impact de ces variables sur les prédictions ;
- Évaluer l'équité du modèle selon différentes métriques (parité démographique, égalité des chances, etc.) ;
- Le cas échéant, appliquer des techniques de débiaisage.

Transparence et explicabilité

Conformément aux principes du HLEG et aux exigences de l'AI Act, le modèle doit être **interprétable** : il ne suffit pas de prédire l'attrition, il faut être en mesure d'expliquer *pourquoi* un employé est identifié comme à risque. L'utilisation de techniques d'explicabilité (importance des variables, SHAP, LIME, etc.) sera privilégiée.

Supervision humaine

Les résultats du modèle doivent servir d'**aide à la décision** et non de décision automatique. Toute action RH fondée sur les prédictions (entretien, formation, ajustement salarial) doit impliquer un jugement humain qualifié, conformément à l'article 22 du RGPD.

Finalité et proportionnalité

Le modèle doit être utilisé dans une finalité légitime : **la rétention des talents et l'amélioration des conditions de travail**, et non la surveillance ou la sanction des employés. Cette distinction est fondamentale pour garantir la conformité éthique et juridique du projet.

2.3 Bonus : cadre indien et comparaison

Notre jeu de données étant issu d'une entreprise basée en Inde, il est intéressant d'examiner le cadre réglementaire indien et de le comparer à l'approche européenne.

2.3.1 Le Digital Personal Data Protection Act (DPDPA, 2023)

L'Inde a adopté le 11 août 2023 sa première loi cadre de protection des données personnelles numériques, le *Digital Personal Data Protection Act* (DPDPA), dont les règles d'application ont été notifiées en novembre 2025 [11].

Contrairement au RGPD qui couvre toutes les données personnelles (numériques ou non), le DPDPA ne s'applique qu'aux **données personnelles numériques**. Il repose principalement sur deux bases juridiques :

- **Le consentement** : libre, spécifique, éclairé, inconditionnel et sans ambiguïté ;
- **Les utilisations légitimes** (Section 7 et Annexe 1) : le traitement est autorisé *sans consentement* pour certaines finalités, notamment les finalités liées à l'emploi (Section 7(i)), la protection de l'employeur contre les pertes, ou la fourniture de services demandés par l'employé.

Les sanctions peuvent atteindre 2,5 milliards INR (environ 28 millions d'euros), un plafond inférieur à celui du RGPD.

2.3.2 Les India AI Governance Guidelines (2025)

Publiées le 5 novembre 2025 par le ministère de l'Électronique et des Technologies de l'Information (MeitY), ces lignes directrices définissent l'approche indienne de la gouvernance de l'IA [12]. L'Inde a fait le choix explicite de **ne pas adopter de loi dédiée à l'IA** à ce stade, en privilégiant une approche « *light-touch* » fondée sur l'adaptation des cadres existants et des principes non contraignants : confiance intégrée, approche centrée sur l'humain, innovation, et équité.

2.3.3 Comparaison synthétique

L'Union européenne adopte une approche **prescriptive et contraignante**, avec une régulation horizontale par niveaux de risque et des obligations strictes pour les systèmes d'IA en RH. L'Inde privilégie une approche **souple et incitative**, fondée sur l'adaptation des lois existantes et des principes non contraignants. Les deux cadres convergent néanmoins sur les principes fondamentaux : transparence, équité, sécurité des données et supervision humaine.

3 Description des données

Quatre sources de données ont été mises à disposition par le service RH de HumanForYou. L'ensemble des sources partagent la clé **EmployeeID** et entretiennent une relation 1 :1, permettant une fusion par jointures successives (LEFT JOIN).

3.1 Données générales (`general_data.csv`)

Ce fichier constitue le socle du jeu de données avec **4 410 employés** décrits par **24 variables**.

Note : les variables **EmployeeCount**, **Over18** et **StandardHours** sont constantes et n'apportent aucune information discriminante ; elles seront supprimées lors du prétraitement.

TABLE 1 – Comparaison des cadres réglementaires UE / Inde

Critère	Union Européenne	Inde
Textes principaux	RGD + AI Act	DPDPA 2023 + AI Guidelines 2025
Portée	Toutes données personnelles	Données numériques uniquement
Bases juridiques	6 bases (consentement, contrat, intérêt légitime, etc.)	2 bases (consentement + utilisations légitimes)
Données employés	Consentement ou base contractuelle avec évaluation	Traitement sans consentement pour finalités d'emploi
Décision automatisée	Interdite (art. 22) sauf exceptions	Pas d'interdiction explicite
Régulation de l'IA	Loi contraignante (AI Act)	Lignes directrices non contraignantes
Systèmes IA en RH	Classés haut risque	Pas de classification par risque
Test de biais	Obligatoire	Recommandé
Supervision humaine	Obligatoire	Recommandée
Sanctions maximales	4 % CA mondial ou 20 M€	2,5 Mds INR ($\approx$ 28 M€)

3.2 Enquête employé (employee_survey_data.csv)

Enquête soumise en juin 2015 (réponse non obligatoire). Trois questions notées sur une échelle de Likert de 1 à 4 :

- `EnvironmentSatisfaction` : satisfaction vis-à-vis de l'environnement de travail ;
- `JobSatisfaction` : satisfaction vis-à-vis du travail ;
- `WorkLifeBalance` : équilibre vie professionnelle / vie personnelle.

3.3 Évaluation manager (manager_survey_data.csv)

Dernière évaluation de chaque employé par son manager (février 2015) :

- `JobInvolvement` : niveau d'implication au travail (1 à 4) ;
- `PerformanceRating` : évaluation de la performance annuelle (1 à 4).

3.4 Horaires de badgeage (in_out_time/)

Deux fichiers (`in_time.csv` et `out_time.csv`) contenant les horodatages d'arrivée et de départ pour chaque jour ouvré de 2015 (261 jours). Ces données brutes ont été agrégées en **six indicateurs** par employé :

3.5 Jeu de données fusionné (dataset_final.csv)

La fusion des quatre sources produit un jeu de données unique de **4 410 lignes** et **35 colonnes**, réalisée par jointures LEFT JOIN successives sur `EmployeeID`. Le script `build_dataset.py` automatise cette opération.

TABLE 2 – Variables principales du fichier `general_data.csv`

Variable	Type	Description
Age	Numérique	Âge de l'employé
Attrition	Catégorielle	Variable cible (Yes/No) : départ en 2016
BusinessTravel	Catégorielle	Fréquence des déplacements professionnels
Department	Catégorielle	Département (Sales, R&D, HR)
DistanceFromHome	Numérique	Distance domicile-travail (km)
Education	Ordinale	Niveau d'éducation (1 à 5)
EducationField	Catégorielle	Domaine d'études
EmployeeCount	Constante	Toujours égal à 1
EmployeeID	Identifiant	Clé primaire
Gender	Catégorielle	Genre (Male/Female)
JobLevel	Ordinale	Niveau hiérarchique (1 à 5)
JobRole	Catégorielle	Intitulé du poste
MaritalStatus	Catégorielle	Statut marital
MonthlyIncome	Numérique	Salaire mensuel (INR)
NumCompaniesWorked	Numérique	Nombre d'entreprises précédentes
Over18	Constante	Toujours Y
PercentSalaryHike	Numérique	Pourcentage d'augmentation salariale
StandardHours	Constante	Toujours 8
StockOptionLevel	Ordinale	Niveau de stock-options (0 à 3)
TotalWorkingYears	Numérique	Années d'expérience totale
TrainingTimesLastYear	Numérique	Formations suivies l'année précédente
YearsAtCompany	Numérique	Ancienneté dans l'entreprise
YearsSinceLastPromotion	Numérique	Années depuis la dernière promotion
YearsWithCurrManager	Numérique	Années avec le manager actuel

TABLE 3 – Variables dérivées des horaires de badgeage

Variable	Description
avg_in_hour	Heure d'arrivée moyenne (format décimal)
avg_out_hour	Heure de départ moyenne
avg_work_hours	Durée de travail journalière moyenne
std_work_hours	Écart-type de la durée de travail (régularité)
nb_days_present	Nombre de jours de présence en 2015
nb_days_absent	Nombre de jours d'absence en 2015

4 Exploration des données

Cette section présente les résultats de l'analyse exploratoire (EDA) réalisée sur le jeu de données fusionné.

4.1 Variable cible : Attrition

Sur les 4 410 employés, **711 ont quitté l'entreprise** en 2016, soit un taux d'attrition de **16,1 %**. Les 3 699 restants (83,9 %) sont demeurés en poste. Ce déséquilibre entre les classes devra être pris en compte lors de la modélisation.




FIGURE 1 – Distribution de la variable cible Attrition (effectifs et proportions)

4.2 Valeurs manquantes

Le jeu de données fusionné présente un faible taux de valeurs manquantes, concentré sur cinq variables :

TABLE 4 – Valeurs manquantes dans le jeu de données fusionné

Variable	Manquantes	Proportion
WorkLifeBalance	38	0,9 %
EnvironmentSatisfaction	25	0,6 %
JobSatisfaction	20	0,5 %
NumCompaniesWorked	19	0,4 %
TotalWorkingYears	9	0,2 %

Les trois premières proviennent de l'enquête employé (réponse non obligatoire), les deux dernières des données générales. Le taux global reste très faible (< 1 % par variable).

4.3 Statistiques descriptives des variables numériques

On observe une forte dispersion des revenus (écart-type de 47069 INR pour une moyenne de 65 029 INR), ce qui reflète la diversité des niveaux hiérarchiques. L'ancienneté moyenne est de 7 ans, avec une médiane à 5 ans, indiquant une distribution asymétrique à droite.




FIGURE 2 – Distribution du nombre de jours d'absence par employé (données de badgeage)

TABLE 5 – Statistiques descriptives des principales variables numériques

Variable	Moyenne	Écart-type	Médiane	Min	Max
Age (années)	36,92	9,13	36	18	60
MonthlyIncome (INR)	65 029	47 069	49 190	10 090	199 990
DistanceFromHome (km)	9,19	8,11	7	1	29
TotalWorkingYears	11,28	7,78	10	0	40
YearsAtCompany	7,01	6,13	5	0	40
PercentSalaryHike (%)	15,21	3,66	14	11	25
YearsSinceLastPromotion	2,19	3,22	1	0	15
YearsWithCurrManager	4,12	3,57	3	0	17
NumCompaniesWorked	2,69	2,50	2	0	9




FIGURE 3 – Distributions des variables numériques clés, segmentées par statut d'attrition

4.4 Variables d'enquête et d'évaluation

TABLE 6 – Statistiques des variables d'enquête (échelle 1–4)

Variable	Moyenne	Écart-type	Médiane
EnvironmentSatisfaction	2,72	1,09	3
JobSatisfaction	2,73	1,10	3
WorkLifeBalance	2,76	0,71	3
JobInvolvement	2,73	0,71	3
PerformanceRating	3,15	0,36	3

La variable **PerformanceRating** présente une particularité : aucun employé n'a reçu une note inférieure à 3, ce qui suggère une évaluation peu discriminante de la part des managers.




FIGURE 4 – Distribution des réponses à l'enquête employé (échelle 1–4)




FIGURE 5 – Distribution des évaluations managériales (JobInvolvement et PerformanceRating)

4.5 Indicateurs issus des horaires de badgeage

L'heure d'arrivée est très homogène (écart-type de 0,02 h), alors que l'heure de départ varie fortement (écart-type de 1,34 h), ce qui se traduit par une grande dispersion de la durée de travail journalière (de 5,95 h à 11,03 h).




FIGURE 6 – Matrice de corrélation entre les variables d'enquête

TABLE 7 – Statistiques des variables temporelles agrégées

Variable	Moyenne	Écart-type	Min	Max
avg_in_hour	9,99	0,02	9,93	10,07
avg_out_hour	17,69	1,34	15,94	21,06
avg_work_hours	7,70	1,34	5,95	11,03
std_work_hours	0,30	0,01	0,26	0,35
nb_days_present	236,27	5,50	225	248
nb_days_absent	24,73	5,50	13	36




FIGURE 7 – Distribution des durées de travail quotidiennes (toutes dates confondues)




FIGURE 8 – Indicateurs agrégés issus des horaires de badgeage

TABLE 8 – Distribution des principales variables catégorielles

Variable	Modalité	Effectif	Proportion
Department	Research & Development	2 883	65,4 %
	Sales	1 338	30,3 %
	Human Resources	189	4,3 %
Gender	Male	2 646	60,0 %
	Female	1 764	40,0 %
MaritalStatus	Married	2 019	45,8 %
	Single	1 410	32,0 %
	Divorced	981	22,2 %
BusinessTravel	Travel_Rarely	3 129	70,9 %
	Travel_Frequently	831	18,8 %
	Non-Travel	450	10,2 %

4.6 Répartition des variables catégorielles

Le département R&D concentre les deux tiers des effectifs. La répartition hommes/femmes est de 60/40. Près de la moitié des employés sont mariés.




FIGURE 9 – Taux d'attrition par variable catégorielle

4.7 Taux d'attrition par catégorie

L'analyse du taux d'attrition par sous-groupe révèle des disparités significatives :

TABLE 9 – Taux d'attrition par catégorie

Variable	Modalité	Départs	Taux
Department	Human Resources	57 / 189	30,2 %
	R&D	453 / 2 883	15,7 %
	Sales	201 / 1 338	15,0 %
MaritalStatus	Single	360 / 1 410	25,5 %
	Married	252 / 2 019	12,5 %
	Divorced	99 / 981	10,1 %
BusinessTravel	Travel_Frequently	207 / 831	24,9 %
	Travel_Rarely	468 / 3 129	15,0 %
	Non-Travel	36 / 450	8,0 %
Gender	Male	441 / 2 646	16,7 %
	Female	270 / 1 764	15,3 %

Trois catégories se démarquent par un taux d'attrition nettement supérieur à la moyenne (16,1 %) :

- Le département **Human Resources** (30,2 %), soit presque le double de la moyenne ;

- Les employés **célibataires** (25,5 %), contre 10,1 % pour les divorcés ;
 - Les **voyageurs fréquents** (24,9 %), soit trois fois plus que les sédentaires (8,0 %).
- En revanche, l'écart entre hommes et femmes est faible (16,7 % vs 15,3 %).

4.8 Comparaison des moyennes selon l'attrition

TABLE 10 – Moyennes des variables numériques selon le statut d'attrition

Variable	Partis (Yes)	Restés (No)	Écart
Age (années)	33,61	37,56	−3,95
MonthlyIncome (INR)	61 683	65 673	−3 990
YearsAtCompany	5,13	7,37	−2,24
TotalWorkingYears	8,26	11,86	−3,60
YearsWithCurrManager	2,85	4,37	−1,52
avg_work_hours	8,32	7,58	+0,74
NumCompaniesWorked	2,94	2,65	+0,29
nb_days_absent	24,19	24,84	−0,65

Les employés ayant quitté l'entreprise sont en moyenne **plus jeunes** (−4 ans), avec **moins d'ancienneté** (−2,2 ans), **moins d'expérience** (−3,6 ans), et une relation plus courte avec leur manager (−1,5 ans). Le résultat le plus notable concerne la **durée de travail journalière** : les employés partis travaillaient en moyenne 8,32 heures par jour contre 7,58 pour ceux restés, soit 45 minutes de plus par jour.

4.9 Corrélations avec l'attrition

Les corrélations de Pearson entre les variables numériques et la variable cible (Attrition encodée en 0/1) mettent en évidence les facteurs les plus associés au départ :

TABLE 11 – Principales corrélations avec l'attrition (valeur absolue décroissante)

Variable	Corrélation	Interprétation
avg_work_hours	+0,202	Plus d'heures → plus de départs
avg_out_hour	+0,202	Départ tardif → plus de départs
TotalWorkingYears	−0,170	Moins d'expérience → plus de départs
Age	−0,159	Plus jeune → plus de départs
YearsWithCurrManager	−0,156	Manager récent → plus de départs
YearsAtCompany	−0,134	Moins d'ancienneté → plus de départs
JobSatisfaction	−0,103	Insatisfaction → plus de départs
EnvironmentSatisfaction	−0,102	Env. insatisfaisant → plus de départs

Les corrélations restent modérées ($\max |r| = 0,20$), ce qui est typique des problèmes de classification binaire avec de nombreuses variables. Les deux facteurs les plus associés sont liés au temps de travail effectif, suivis par les variables d'ancienneté et de satisfaction.

4.10 Variables à variance nulle

Trois variables présentent une variance nulle et seront supprimées :

- `EmployeeCount` : toujours égal à 1 ;
- `Over18` : toujours « Y » ;
- `StandardHours` : toujours égal à 8.

5 Prétraitement

À compléter : gestion des valeurs manquantes, suppression des variables constantes, encodage des variables catégorielles, normalisation/standardisation, sélection de features, gestion du déséquilibre des classes.

6 Modélisation

À compléter : choix des modèles (régression logistique, arbres de décision, forêt aléatoire, gradient boosting, etc.), entraînement, validation croisée, recherche d'hyperparamètres, métriques de performance (accuracy, precision, recall, F1-score, AUC-ROC).

7 Résultats et interprétation

À compléter : importance des variables, analyse des facteurs de turnover, explicabilité du modèle, recommandations stratégiques.

8 Conclusion

À compléter : synthèse des résultats, limites du projet, perspectives d'amélioration.

Références

- [1] CNIL, *Comprendre le RGPD*, <https://www.cnil.fr/fr/comprendre-le-rgpd>.
- [2] CNIL, *Guide de la sécurité des données personnelles*, édition 2023, https://www.cnil.fr/sites/cnil/files/2023-04/cnil_guide_securite_des_donnees_personnelles-2023.pdf.
- [3] CNIL, *Comment permettre à l'Homme de garder la main ? Rapport sur les enjeux éthiques des algorithmes et de l'intelligence artificielle*, décembre 2017, <https://www.cnil.fr/fr/comment-permettre-lhomme-de-garder-la-main-rapport-sur-les-enjeux-ethiques-des-a>.
- [4] CNIL, *Lignes directrices et recommandations*, <https://www.cnil.fr/en/decisions/lignes-directrices-recommandations-CNIL>.
- [5] Parlement européen et Conseil de l'Union européenne, *Règlement (UE) 2024/1689 établissant des règles harmonisées concernant l'intelligence artificielle (AI Act)*, Journal officiel, 13 juin 2024. Considérant 27, <https://artificialintelligenceact.eu/fr/recital/27/>.
- [6] Groupe d'experts de haut niveau sur l'IA, *Lignes directrices en matière d'éthique pour une IA digne de confiance*, Commission européenne, 2019, https://ec.europa.eu/newsroom/dae/document.cfm?doc_id=60427.
- [7] Villani, C. et al., *Donner un sens à l'intelligence artificielle : pour une stratégie nationale et européenne*, rapport au Premier ministre, mars 2018, <https://www.vie-publique.fr/rapport/37225-donner-un-sens-lintelligence-artificielle-pour-une-strategie-nation>.
- [8] Hub France IA, *Guide pratique IA éthique*, version 2, décembre 2024, https://www.hub-franceia.fr/wp-content/uploads/2024/12/Guide_pratique_IA_ethique_version-2.pdf.
- [9] Centre de politique européenne, *Lignes directrices en matière d'éthique pour l'IA : analyse de la communication COM(2019) 168*, https://www.cep.eu/fileadmin/user_upload/cep.eu/Analysen/COM_2019_168_Ethik_in_KI/CA_COM_2019_168__Lignes_directrices_en_matiere_d_ethique_pour_l_IA.pdf.
- [10] Commission européenne, *Lignes directrices relatives à l'utilisation de l'intelligence artificielle*, 2022, https://teachertaskforce.org/sites/default/files/2023-06/2022_EC_lignes-directrices-utilisation-IA_FR.pdf.
- [11] Government of India, *The Digital Personal Data Protection Act, 2023* (No. 22 of 2023), 11 août 2023. Règles d'application notifiées en novembre 2025, <https://www.meity.gov.in/static/uploads/2024/06/2bf1f0e9f04e6fb4f8fef35e82c42aa5.pdf>.
- [12] Ministry of Electronics and Information Technology (MeitY), *India AI Governance Guidelines*, 5 novembre 2025, <https://indiaai.gov.in/article/india-ai-governance-guidelines-empowering-ethical-and-responsible-ai>.
- [13] Quantmetry (Capgemini), *Intelligence artificielle et éthique : comment définir et mesurer l'équité algorithmique*, <https://www.quantmetry.com/blog/intelligence-artificielle-et-ethique-comment-definir-et-mesurer-lequite-algorithm>.