

Projet Bloc IA

Analyse du turnover chez HumanForYou

Maxence Chartier

Amine Haouri

Anisse Imerzoukene

Mourad Messaoudi

27 mars 2026

Table des matières

1	Introduction	3
1.1	Contexte historique : des dérives aux législations	3
1.1.1	Tout commence par les fichiers : la naissance de la méfiance (années 1970)	3
1.1.2	La surveillance à l'ère numérique : quand les États dépassent les bornes (2001–2013)	3
1.1.3	L'ère du <i>big data</i> : quand les entreprises exploitent sans limites (2016–2018)	4
1.1.4	L'IA qui discrimine : le choc des biais algorithmiques (2016–2018)	4
1.1.5	La surveillance au travail et la prédiction comportementale : des dérives proches de notre sujet	5
1.1.6	Le spectre du contrôle total : Clearview AI et le crédit social	5
1.1.7	Du constat à la régulation : la chronologie d'une prise de conscience . . .	6
1.2	Objectifs du projet	6
2	Cadre réglementaire et éthique	7
2.1	Cadre réglementaire européen	7
2.1.1	Le Règlement Général sur la Protection des Données (RGPD)	7
2.1.2	La loi européenne sur l'intelligence artificielle (AI Act)	8
2.1.3	Les sept principes éthiques pour une IA digne de confiance	8
2.1.4	Cadre français : contributions majeures	9
2.2	Contributions de la DARPA (États-Unis)	9
2.2.1	Programmes majeurs liés à l'IA	9
2.2.2	Influence sur l'éthique de l'IA	10
2.3	Définitions : éthique et équité en intelligence artificielle	10
2.3.1	L'éthique en intelligence artificielle	11
2.3.2	L'équité en intelligence artificielle	11
2.4	Décisions et règles adoptées pour le projet	12
2.4.1	Positionnement du système	12
2.4.2	Règles de traitement des données	13
2.4.3	Règles d'équité et de non-discrimination	13
2.4.4	Règles de transparence et d'explicabilité	13
2.4.5	Règles de gouvernance et de supervision	13
2.5	Application au projet HumanForYou sous le cadre européen	14
3	Conclusion	15

1 Introduction

L'entreprise **HumanForYou**, acteur du secteur des ressources humaines basé en Inde, fait face à un taux de turnover préoccupant parmi ses employés. Dans un contexte où la rétention des talents constitue un enjeu stratégique majeur, la direction souhaite exploiter les données RH disponibles pour comprendre les facteurs de départ et anticiper les risques d'attrition.

Avant de présenter les objectifs du projet, il est essentiel de comprendre *pourquoi* l'utilisation de l'IA dans les ressources humaines est aujourd'hui encadrée par des législations strictes. Cette réglementation n'est pas née dans un vide : elle est le fruit d'une histoire jalonnée de dérives, de scandales et de prises de conscience progressives.

1.1 Contexte historique : des dérives aux législations

La réglementation qui encadre aujourd'hui l'intelligence artificielle et la protection des données n'est pas apparue spontanément. Elle est le produit d'une histoire de plus de cinquante ans, faite de projets ambitieux qui ont dérapé, de scandales qui ont choqué l'opinion, et de prises de conscience successives. Chaque étape a nourri la suivante, dessinant progressivement le cadre juridique dans lequel notre projet s'inscrit.

1.1.1 Tout commence par les fichiers : la naissance de la méfiance (années 1970)

L'histoire débute bien avant l'intelligence artificielle, à une époque où l'informatique commence tout juste à s'imposer dans les administrations. En 1974, la France découvre le projet **SAFARI** (Système Automatisé pour les Fichiers Administratifs et le Répertoire des Individus) : le gouvernement prévoit d'interconnecter l'ensemble des fichiers administratifs français — impôts, sécurité sociale, police, état civil — via le numéro de sécurité sociale. L'ambition est de « rationaliser » la gestion publique, mais le résultat serait un fichage complet de chaque citoyen.

Le journal *Le Monde* titre « SAFARI ou la chasse aux Français », et l'indignation est immédiate. Ce scandale conduit directement à l'adoption de la **loi Informatique et Libertés** du 6 janvier 1978 et à la création de la **CNIL** — l'une des premières autorités de protection des données au monde. Le message est clair : même avec de bonnes intentions, le croisement massif de données personnelles représente une menace pour les libertés individuelles.

Ce premier avertissement pose un principe qui traversera les décennies suivantes : *ce n'est pas parce qu'on peut collecter et croiser des données qu'on doit le faire.*

1.1.2 La surveillance à l'ère numérique : quand les États dépassent les bornes (2001–2013)

Trente ans plus tard, la même question resurgit à une tout autre échelle. Après les attentats du 11 septembre 2001, le Pentagone lance le programme **Total Information Awareness** (TIA), qui vise à croiser massivement les données personnelles — transactions bancaires, communications, déplacements — pour détecter les menaces terroristes avant qu'elles ne se concrétisent. Le programme est officiellement abandonné en 2003 face à la pression du Congrès américain, qui y voit les prémices d'un État de surveillance.

Mais l'histoire ne s'arrête pas là. En 2013, Edward Snowden révèle que la NSA a poursuivi cette logique sous d'autres noms : **PRISM** permet d'accéder directement aux données des géants du numérique (Google, Facebook, Apple), tandis que **XKeyscore** permet de fouiller en temps réel les communications mondiales. Ces révélations provoquent un séisme politique, en particulier en Europe, où l'on découvre que les données des citoyens européens sont aspirées sans aucun garde-fou.

C'est cette prise de conscience qui accélère l'adoption du **RGD** par le Parlement européen en 2016 : l'Europe décide qu'il est temps de reprendre le contrôle sur les données de ses citoyens, non seulement face aux États, mais aussi face aux entreprises privées qui accumulent des volumes de données sans précédent. Le RGD entre en application le 25 mai 2018, imposant pour la première fois des sanctions réellement dissuasives (jusqu'à 4 % du chiffre d'affaires mondial).

1.1.3 L'ère du *big data* : quand les entreprises exploitent sans limites (2016–2018)

Mais à peine le RGD est-il entré en vigueur qu'un scandale vient démontrer l'ampleur du problème. En mars 2018, le *New York Times* et *The Guardian* révèlent l'affaire **Cambridge Analytica** : la société britannique a exploité les données personnelles de **87 millions d'utilisateurs Facebook**, collectées via une application tierce apparemment anodine (un quiz de personnalité), pour construire des profils psychologiques et cibler des messages politiques personnalisés lors de la campagne présidentielle américaine de 2016 et du référendum sur le Brexit.

Le scandale ne réside pas seulement dans la collecte non consentie : il réside dans l'*usage*. Les données personnelles ne servent plus à vendre des publicités — elles deviennent une **arme de manipulation démocratique**. Facebook est condamné à une amende record de 5 milliards de dollars par la FTC, et l'affaire devient le symbole d'une ère où les données personnelles sont le nouveau pétrole — et où ceux qui les détiennent peuvent en abuser à grande échelle.

C'est dans ce climat que les législateurs européens commencent à comprendre que protéger les données ne suffit plus : il faut aussi encadrer les *algorithmes* qui les exploitent.

1.1.4 L'IA qui discrimine : le choc des biais algorithmiques (2016–2018)

Car au-delà de la collecte abusive, un problème plus insidieux émerge : les algorithmes d'IA, même bien intentionnés, peuvent **reproduire et amplifier les discriminations humaines**.

En 2016, le média d'investigation ProPublica publie une enquête retentissante sur **COMPAS** (*Correctional Offender Management Profiling for Alternative Sanctions*), un logiciel utilisé par des tribunaux américains pour évaluer le risque de récidive des accusés. L'enquête révèle que le système **surestimait systématiquement le risque pour les accusés afro-américains** : ceux-ci avaient presque deux fois plus de chances d'être faussement étiquetés comme futurs criminels que les accusés blancs. Le modèle, entraîné sur des données historiques reflétant des décennies de discrimination systémique dans la justice américaine, avait appris à perpétuer ces biais.

Ce cas a provoqué un débat fondamental : peut-on confier des décisions qui affectent la vie des gens à des algorithmes opaques ? La chercheuse Alexandra Chouldechova a démontré en 2017, en réponse directe à l'affaire COMPAS, un résultat mathématique troublant : **il est impossible de satisfaire simultanément toutes les définitions**

de l'équité algorithmique. Autrement dit, rendre un algorithme « juste » implique nécessairement un choix éthique explicite — il n'existe pas de neutralité technique.

Deux ans plus tard, le problème frappe directement le monde des ressources humaines. En 2018, Reuters révèle qu'**Amazon** avait développé un outil de recrutement basé sur l'IA qui **discriminait systématiquement les femmes**. Entraîné sur dix ans de CV reçus — majoritairement masculins dans le secteur technologique — le modèle avait appris à pénaliser les CV contenant le mot « women's » (comme « women's chess club ») et à favoriser les formulations typiquement masculines. Amazon a abandonné le projet, mais le mal était fait : le cas est devenu l'exemple emblématique des **biais algorithmiques en RH**, et exactement le type de risque que notre projet de prédiction d'attrition doit anticiper.

1.1.5 La surveillance au travail et la prédiction comportementale : des dérives proches de notre sujet

Ces scandales n'ont pas touché que le recrutement. Dans le domaine même de la gestion des employés — le cœur de notre projet — plusieurs dérives ont fait surface et illustrent les dangers d'une IA mal encadrée.

En 2017, des enquêtes révèlent qu'**Uber** utilisait des algorithmes pour détecter les chauffeurs susceptibles de rejoindre un mouvement de grève ou de quitter la plateforme, et leur proposait des incitations ciblées (bonus, courses avantageuses) pour les en dissuader. En d'autres termes, Uber faisait exactement ce que notre projet propose — de la prédiction d'attrition — mais l'utilisait à des fins de **manipulation** plutôt que d'amélioration des conditions de travail. La frontière entre aide à la décision et contrôle social est mince.

En 2019, l'entreprise **HireVue** proposait un outil d'entretien vidéo analysant les expressions faciales et le ton de voix des candidats pour prédire leur performance future. L'Electronic Privacy Information Center (EPIC) a déposé une plainte, arguant que le système était opaque et potentiellement discriminatoire. Sous la pression publique et réglementaire, HireVue a fini par abandonner l'analyse faciale en 2021.

Enfin, en 2020, la banque **Barclays** a été contrainte d'abandonner un logiciel de surveillance qui traquait le temps passé par chaque employé à son bureau, ses pauses et sa productivité en temps réel. L'affaire, révélée par le *Daily Telegraph*, a provoqué l'intervention de l'Information Commissioner's Office (ICO) britannique. Le message est clair : même dans un cadre professionnel, la surveillance algorithmique a des limites.

1.1.6 Le spectre du contrôle total : Clearview AI et le crédit social

Parallèlement à ces dérives sectorielles, deux cas ont cristallisé les craintes les plus profondes de la société civile.

La start-up américaine **Clearview AI** a constitué une base de données de plus de **3 milliards d'images faciales** en aspirant sans autorisation les photos publiées sur les réseaux sociaux. Cette base était vendue à des forces de l'ordre et des entreprises privées pour identifier n'importe quel individu à partir d'une simple photo. En 2022, la CNIL a infligé à Clearview une amende de **20 millions d'euros**, et l'entreprise a été sanctionnée dans plusieurs pays. Ce cas a montré que la collecte massive de données biométriques, sans consentement et sans finalité définie, pouvait transformer tout espace public en un dispositif de surveillance.

Mais c'est peut-être le **système de crédit social chinois**, déployé progressivement depuis 2014, qui incarne le mieux le scénario que les régulateurs européens cherchent

à prévenir. Ce système agrège des données comportementales — paiements, infractions, activité en ligne, relations sociales — pour attribuer à chaque citoyen un score influençant son accès au crédit, aux transports, à l’emploi et aux services publics. L’AI Act européen cite explicitement ce type de système comme un **risque inacceptable** (article 5) : les systèmes de notation sociale y sont purement et simplement interdits.

1.1.7 Du constat à la régulation : la chronologie d’une prise de conscience

Chacun de ces scandales a laissé une trace dans le paysage législatif. Vue d’ensemble, la chronologie dessine une accélération :

1. **1978** : loi Informatique et Libertés en France, en réaction au projet SAFARI ;
2. **2016** : adoption du RGPD par le Parlement européen, catalysée par les révélations Snowden et la prise de conscience sur la valeur des données personnelles ;
3. **2019** : publication des lignes directrices éthiques du HLEG européen, en réponse aux scandales Cambridge Analytica et Amazon ;
4. **2021** : proposition de l’AI Act par la Commission européenne, motivée par les affaires COMPAS, Clearview AI et la crainte d’un « crédit social à l’européenne » ;
5. **2023** : adoption du DPDPA indien, dans un contexte de pression internationale et de scandales locaux liés à Aadhaar (fuites de données biométriques de plus d’un milliard de citoyens indiens) ;
6. **2024** : entrée en vigueur de l’AI Act, premier cadre juridique contraignant au monde spécifiquement dédié à l’intelligence artificielle.

C’est dans ce contexte historique que s’inscrit notre projet. L’utilisation de l’IA pour prédire l’attrition des employés touche directement aux enjeux soulevés par ces affaires : les biais algorithmiques d’Amazon montrent ce qui arrive quand un modèle RH apprend sur des données biaisées ; la surveillance de Barclays illustre la frontière entre analyse et contrôle ; la manipulation d’Uber rappelle qu’un même outil — la prédiction d’attrition — peut servir l’employé ou l’asservir, selon l’intention de celui qui le déploie. Comprendre cette histoire n’est pas un exercice académique : c’est une condition préalable pour concevoir un système **responsable, équitable et conforme**.

1.2 Objectifs du projet

Ce projet s’inscrit dans le cadre du bloc de formation en Intelligence Artificielle et poursuit plusieurs objectifs :

1. **Analyser le cadre réglementaire et éthique** entourant l’utilisation de l’IA appliquée aux données RH ;
2. **Explorer et préparer les données** issues de quatre sources distinctes (données générales, enquêtes, évaluations managériales, horaires de badgeage) ;
3. **Construire des modèles prédictifs** de l’attrition à l’aide de techniques de régression et de classification ;
4. **Formuler des recommandations** concrètes et actionnables à destination de la direction de HumanForYou.

L’enjeu final n’est pas seulement de produire un modèle performant, mais de transformer les résultats en recommandations stratégiques compréhensibles par un décideur.

Bien que le jeu de données provienne d’une entreprise indienne, nous nous plaçons **dans le cadre réglementaire européen** (RGPD, AI Act) pour analyser les enjeux éthiques et juridiques, celui-ci constituant le cadre le plus exigeant et le plus complet à ce jour.

2 Cadre réglementaire et éthique

L’utilisation de l’intelligence artificielle dans le domaine des ressources humaines — notamment pour la prédiction de l’attrition des employés — soulève des questions éthiques et juridiques majeures. Nous nous plaçons ici dans le cadre européen, comme si le projet était déployé au sein de l’Union européenne.

2.1 Cadre réglementaire européen

2.1.1 Le Règlement Général sur la Protection des Données (RGPD)

Le RGPD, entré en vigueur le 25 mai 2018, constitue le socle de la protection des données personnelles dans l’Union européenne. Il s’applique à tout traitement de données personnelles, qu’elles soient numériques ou non [1].

Principes fondamentaux

Le règlement repose sur plusieurs principes clés directement applicables à notre projet :

- **Licéité, loyauté et transparence** : tout traitement doit reposer sur une base juridique valide (consentement, exécution d’un contrat, intérêt légitime, etc.) ;
- **Limitation des finalités** : les données ne peuvent être traitées que pour des fins déterminées et légitimes ;
- **Minimisation des données** : seules les données strictement nécessaires doivent être collectées ;
- **Exactitude** : les données doivent être tenues à jour et exactes ;
- **Limitation de la conservation** : les données ne doivent pas être conservées au-delà de la durée nécessaire ;
- **Intégrité et confidentialité** : des mesures techniques et organisationnelles appropriées doivent garantir la sécurité des données [2].

Article 22 — Décision individuelle automatisée

L’article 22 du RGPD est particulièrement pertinent pour notre projet. Il interdit, en principe, les décisions fondées exclusivement sur un traitement automatisé produisant des effets juridiques ou significatifs sur une personne. Dans le contexte RH, cela signifie qu’un modèle de prédiction de l’attrition **ne peut pas**, à lui seul, fonder une décision de licenciement, de mutation ou de rétrogradation. Trois exceptions sont prévues :

1. La décision est nécessaire à l’exécution d’un contrat ;
2. Elle est autorisée par le droit avec des garanties appropriées ;
3. Elle repose sur le consentement explicite de la personne concernée.

Dans tous les cas, la personne doit pouvoir obtenir une intervention humaine, exprimer son point de vue et contester la décision.

2.1.2 La loi européenne sur l'intelligence artificielle (AI Act)

Le règlement (UE) 2024/1689, dit *AI Act*, est entré en vigueur le 1^{er} août 2024 avec une application progressive (exigences pour les systèmes à haut risque applicables au 2 août 2026). Il instaure une classification des systèmes d'IA selon leur niveau de risque [5].

Classification par risque

- **Risque inacceptable** : systèmes interdits (notation sociale, manipulation subliminale, etc.) ;
- **Risque élevé** : systèmes soumis à des obligations strictes ;
- **Risque limité** : obligations de transparence ;
- **Risque minimal** : libre utilisation.

Les systèmes IA en RH : risque élevé

L'annexe III de l'AI Act classe explicitement comme **à haut risque** les systèmes d'IA utilisés dans le domaine de l'emploi, notamment pour :

- Le recrutement et la sélection de candidats ;
- Les décisions de promotion et de résiliation ;
- L'évaluation des performances et du comportement ;
- Le suivi et l'allocation des tâches.

Un système de prédiction de l'attrition tel que le nôtre relève très probablement de cette catégorie dès lors que ses résultats peuvent influencer des décisions relatives à la gestion du personnel.

Obligations pour les systèmes à haut risque

1. **Système de gestion des risques** : identification et atténuation des risques de biais, de discrimination et d'erreurs ;
2. **Gouvernance des données** : données d'entraînement de haute qualité (exactitude, complétude, représentativité), test de biais obligatoire ;
3. **Documentation et transparence** : documentation technique complète, notices d'utilisation, information des personnes concernées ;
4. **Contrôle humain** : supervision humaine effective, capacité d'intervention et de correction, personnel formé ;
5. **Évaluation d'impact** : réalisation d'une analyse d'impact relative à la protection des données (AIPD) avant déploiement.

2.1.3 Les sept principes éthiques pour une IA digne de confiance

Le Groupe d'Experts de Haut Niveau sur l'IA (HLEG), nommé par la Commission européenne, a défini en 2019 sept principes éthiques non contraignants, rappelés dans le considérant 27 de l'AI Act [6, 5] :

1. **Intervention humaine et supervision** : l'IA comme outil au service de l'humain ;
2. **Robustesse technique et sécurité** : résilience face aux erreurs et aux tentatives de détournement ;
3. **Protection de la vie privée et gouvernance des données** : conformité aux règles de protection des données ;

4. **Transparence** : traçabilité, explicabilité, information claire des utilisateurs ;
5. **Diversité, non-discrimination et équité** : prévention des biais et des effets discriminatoires ;
6. **Bien-être sociétal et environnemental** : IA durable et au service de tous ;
7. **Responsabilité** : mécanismes de reddition de comptes.

2.1.4 Cadre français : contributions majeures

Rapport de la CNIL (2017)

La Commission Nationale de l’Informatique et des Libertés a publié en décembre 2017 un rapport intitulé « *Comment permettre à l’Homme de garder la main ?* », issu d’un débat public réunissant 3 000 participants. Ce rapport pose deux principes fondateurs [3] :

- **Loyauté** : les algorithmes doivent servir les intérêts des utilisateurs en tant que citoyens, et non seulement en tant que consommateurs ;
- **Vigilance et réflexivité** : questionnement régulier et méthodique des systèmes algorithmiques par tous les acteurs.

Il formule six recommandations opérationnelles : former à l’éthique, rendre les systèmes compréhensibles, concevoir au service de la liberté humaine, constituer une plateforme nationale d’audit, encourager la recherche éthique, et renforcer la fonction éthique en entreprise.

Rapport Villani (2018)

Le rapport « *Donner un sens à l’intelligence artificielle* », remis au Premier ministre par Cédric Villani en mars 2018, définit une stratégie nationale et européenne en IA couvrant six dimensions : politique économique des données, recherche, emploi et transformation du travail, enjeux écologiques, cadre éthique, et inclusivité [7].

2.2 Contributions de la DARPA (États-Unis)

La *Defense Advanced Research Projects Agency* (DARPA), agence du département de la Défense des États-Unis, joue un rôle précurseur dans le développement de l’intelligence artificielle depuis les années 1960. Bien que ses travaux soient principalement orientés vers des applications militaires et de sécurité nationale, ils ont profondément influencé le paysage civil de l’IA et les réflexions internationales sur l’éthique algorithmique.

2.2.1 Programmes majeurs liés à l’IA

XAI — Explainable Artificial Intelligence (2017–2021)

Le programme **XAI** (*Explainable Artificial Intelligence*) est particulièrement pertinent pour notre projet. Lancé en 2017, il visait à développer des techniques permettant aux systèmes d’IA de **justifier leurs décisions** de manière compréhensible par un opérateur humain. Ce programme a donné naissance à des outils aujourd’hui largement utilisés dans le monde civil, notamment les méthodes d’explicabilité post-hoc (SHAP, LIME) que nous mobilisons dans ce projet. L’idée fondatrice de XAI — qu’un modèle performant mais opaque est insuffisant pour la prise de décision — est devenue un principe central de l’AI Act européen [11].

AI Next Campaign (2018–présent)

Lancée en 2018 avec un investissement de plus de 2 milliards de dollars, la campagne **AI Next** explore la « troisième vague » de l’IA : des systèmes capables non seulement de classer et prédire, mais aussi de **comprendre le contexte**, raisonner et s’adapter à de nouvelles situations. Cette vision dépasse les modèles statistiques que nous utilisons dans ce projet, mais elle illustre la trajectoire vers des systèmes d’IA de plus en plus autonomes — et donc les enjeux croissants de supervision humaine.

KAAS — Knowledge-directed Artificial Intelligence Reasoning Over Schemas

Ce programme développe des systèmes capables de raisonnement contextuel en intégrant des connaissances structurées. Dans le domaine RH, une telle approche permettrait à un modèle de prédiction de l’attrition de prendre en compte des facteurs contextuels (conjoncture économique, restructuration en cours) qui ne figurent pas dans les données tabulaires.

LwLL — Learning with Less Labels

Le programme **LwLL** vise à réduire la dépendance des modèles d’IA aux grands volumes de données étiquetées. Cet enjeu est directement pertinent pour les projets RH, où les données sont souvent limitées en volume (quelques milliers d’employés) et où l’étiquetage (départ effectif vs maintien) ne concerne qu’une minorité de cas — exactement le déséquilibre 84/16 que nous observons dans notre jeu de données.

2.2.2 Influence sur l’éthique de l’IA

Les travaux de la DARPA ont contribué à structurer le débat international sur l’IA responsable de plusieurs manières :

- **Explicabilité comme exigence opérationnelle** : le programme XAI a démontré que la transparence des modèles n’est pas seulement une question éthique mais une nécessité pratique pour la confiance et l’adoption ;
- **Robustesse et fiabilité** : les travaux sur l’IA adversariale (*Guaranteeing AI Robustness against Deception*, GARD) ont mis en lumière la vulnérabilité des modèles aux perturbations, renforçant l’exigence de robustesse que l’on retrouve dans l’AI Act ;
- **Approche centrée sur l’humain** : la doctrine *human-in-the-loop* (humain dans la boucle), née dans le contexte militaire, est devenue un pilier de la régulation européenne (article 14 de l’AI Act sur la supervision humaine).

Si l’approche américaine reste globalement moins réglementaire que l’eupéenne — les États-Unis privilégient l’autorégulation sectorielle et les lignes directrices volontaires — les contributions techniques de la DARPA ont paradoxalement fourni les outils (explicabilité, robustesse, audit) qui permettent aujourd’hui de satisfaire les exigences contraignantes de l’AI Act.

2.3 Définitions : éthique et équité en intelligence artificielle

Avant d’appliquer les principes réglementaires à notre projet, il est essentiel de définir précisément deux notions fondamentales qui traversent l’ensemble du cadre juridique et technique : **l’éthique** et **l’équité**.

2.3.1 L'éthique en intelligence artificielle

Définition

L'**éthique de l'IA** désigne la branche de la philosophie morale appliquée aux systèmes d'intelligence artificielle. Elle interroge les principes et les valeurs qui doivent guider la conception, le développement, le déploiement et l'utilisation des systèmes d'IA. Contrairement à la réglementation, qui impose des obligations juridiques, l'éthique relève d'une démarche volontaire et réflexive visant à déterminer ce qui est *juste, bon* et *souhaitable* dans l'usage de ces technologies [3].

Dimensions de l'éthique en IA

L'éthique de l'IA se décline selon plusieurs dimensions complémentaires :

- **Éthique de la conception** (*ethics by design*) : intégrer les principes éthiques dès la phase de développement du système, et non comme un correctif a posteriori. Cela implique par exemple de choisir des métriques d'évaluation qui reflètent les valeurs souhaitées (recall plutôt qu'accuracy dans notre cas, pour ne pas invisibiliser les départs) ;
- **Éthique de l'usage** : s'assurer que le système est utilisé conformément à sa finalité déclarée. Un modèle de prédiction de l'attrition conçu pour améliorer les conditions de travail ne doit pas être détourné pour surveiller ou sanctionner les employés ;
- **Éthique de la responsabilité** : définir clairement qui est responsable des décisions prises avec l'aide du système — le développeur, l'entreprise utilisatrice, le manager qui agit sur la prédiction ? ;
- **Éthique des données** : questionner la légitimité de la collecte, la représentativité des données d'entraînement et le respect de la vie privée des personnes concernées.

Application à notre projet

Dans le contexte de la prédiction de l'attrition chez HumanForYou, l'éthique nous impose de nous poser plusieurs questions fondamentales : est-il légitime de prédire le comportement futur d'un employé à partir de ses données personnelles ? Le bénéfice attendu (rétention, amélioration des conditions) justifie-t-il l'intrusion dans la vie professionnelle ? Comment garantir que les prédictions ne stigmatisent pas certains profils d'employés ?

2.3.2 L'équité en intelligence artificielle

Définition

L'**équité algorithmique** (*fairness*) désigne la propriété d'un système d'IA à traiter de manière juste et non discriminatoire les individus ou les groupes, indépendamment de leurs caractéristiques protégées (genre, âge, origine ethnique, statut marital, etc.). L'équité ne se réduit pas à l'absence de discrimination intentionnelle : un modèle peut être discriminatoire de manière indirecte, en reproduisant ou en amplifiant des biais présents dans les données historiques [12].

Les différentes définitions mathématiques de l'équité

L'un des défis majeurs de l'équité algorithmique est qu'il n'existe pas de définition unique et universelle. Plusieurs métriques, parfois contradictoires entre elles, coexistent :

- **Parité démographique** (*demographic parity*) : le taux de prédiction positive doit être identique entre les groupes. Formellement : $P(\hat{Y} = 1 \mid A = a) = P(\hat{Y} = 1 \mid A = b)$ pour tout attribut protégé A ;

- **Égalité des chances** (*equalized odds*) : les taux de vrais positifs (recall) et de faux positifs doivent être identiques entre les groupes : $P(\hat{Y} = 1 \mid Y = y, A = a) = P(\hat{Y} = 1 \mid Y = y, A = b)$ pour $y \in \{0, 1\}$;
- **Calibration** (*predictive parity*) : la probabilité qu’une prédiction positive soit correcte doit être la même entre les groupes : $P(Y = 1 \mid \hat{Y} = 1, A = a) = P(Y = 1 \mid \hat{Y} = 1, A = b)$;
- **Équité individuelle** : des individus similaires doivent recevoir des prédictions similaires, indépendamment de leur appartenance à un groupe.

Le théorème d’impossibilité

Un résultat fondamental en équité algorithmique, démontré par Chouldechova (2017) et Kleinberg *et al.* (2016), établit qu’il est **mathématiquement impossible de satisfaire simultanément** la parité démographique, l’égalité des chances et la calibration, sauf dans le cas trivial où les taux de base sont identiques entre les groupes. Ce théorème impose un **choix éthique explicite** : quelle définition de l’équité est la plus pertinente pour le contexte d’usage ?

Application à notre projet

Dans le contexte RH de HumanForYou, nous privilégions l’**égalité des chances** comme métrique d’équité principale. En effet, il est essentiel que le modèle détecte les employés à risque avec la même efficacité quel que soit leur genre ou leur âge. Une parité démographique stricte serait moins pertinente, car les taux d’attrition réels peuvent légitimement varier entre groupes en raison de facteurs structurels (conditions de travail différentes selon les départements, par exemple). L’exploration a montré un écart d’attrition faible entre genres (16,7 % vs 15,3 %), ce qui est encourageant.

2.4 Décisions et règles adoptées pour le projet

À la lumière du cadre réglementaire (RGPD, AI Act), des principes éthiques et des exigences d’équité, nous formulons ci-dessous les **décisions structurantes** et les **règles** que nous nous engageons à suivre tout au long de ce projet.

2.4.1 Positionnement du système

1. **Aide à la décision, jamais décision automatique.** Conformément à l’article 22 du RGPD et à l’article 14 de l’AI Act, le modèle de prédiction de l’attrition est strictement positionné comme un **outil d’aide à la décision**. Aucune action RH (entretien, formation, mobilité, ajustement salarial) ne pourra être déclenchée automatiquement par une prédiction du modèle. Toute décision implique l’intervention d’un responsable RH qualifié.
2. **Finalité légitime et explicite.** Le système a pour unique finalité l’**amélioration de la rétention des talents et des conditions de travail**. Il est interdit de l’utiliser à des fins de surveillance, de sanction, de classement des employés ou de justification de licenciements.
3. **Information des employés.** Conformément au principe de transparence du RGPD, les employés doivent être informés de l’existence du système, de sa finalité, des données utilisées et de leur droit de contestation.

2.4.2 Règles de traitement des données

1. **Minimisation.** Seules les variables strictement nécessaires à la prédiction sont conservées. Les variables constantes, redondantes ou non informatives sont supprimées dès le prétraitement.
2. **Pseudonymisation.** Les données sont manipulées via des identifiants numériques (`EmployeeID`). Aucune donnée nominative (nom, prénom, adresse) n'est utilisée ni stockée dans le cadre du projet.
3. **Conservation limitée.** Les données et le modèle sont conservés uniquement pour la durée nécessaire à l'analyse. Tout déploiement opérationnel nécessiterait une **analyse d'impact relative à la protection des données** (AIPD) préalable.
4. **Pas de données sensibles au sens du RGPD.** Le jeu de données ne contient pas de catégories de données sensibles (origines ethniques, opinions politiques, données de santé). Les variables `Gender`, `MaritalStatus` et `Age`, bien qu'elles soient des attributs protégés, ne sont pas des données sensibles au sens de l'article 9 du RGPD.

2.4.3 Règles d'équité et de non-discrimination

1. **Conservation des attributs protégés.** Les variables `Gender`, `MaritalStatus` et `Age` sont conservées dans le modèle plutôt que supprimées. Leur suppression pourrait paradoxalement dégrader l'équité si d'autres variables en sont des proxys (`MonthlyIncome` comme proxy du genre, par exemple).
2. **Audit d'équité systématique.** Après entraînement, le modèle est évalué selon les métriques d'égalité des chances : le recall et le taux de faux positifs sont comparés entre genres et entre tranches d'âge. Un écart supérieur à 5 points de pourcentage déclenchera une investigation.
3. **Débiaisage si nécessaire.** Si un biais significatif est détecté, des techniques de correction post-traitement (ajustement des seuils de décision par groupe) seront appliquées, en privilégiant les méthodes qui ne dégradent pas la performance globale.

2.4.4 Règles de transparence et d'explicabilité

1. **Explicabilité individuelle.** Pour chaque employé identifié comme « à risque », le système fournit une explication des facteurs ayant contribué à la prédiction (via SHAP), permettant au responsable RH de comprendre et de contextualiser l'alerte.
2. **Explicabilité globale.** Un classement des facteurs d'attrition à l'échelle de l'entreprise est produit, permettant d'orienter les politiques RH structurelles.
3. **Documentation complète.** Conformément à l'AI Act, le système est accompagné d'une documentation technique décrivant les données utilisées, les choix de modélisation, les performances obtenues et les limites identifiées.

2.4.5 Règles de gouvernance et de supervision

1. **Supervision humaine continue.** Les prédictions alimentent un tableau de bord consulté par les responsables RH. Le modèle ne déclenche aucune action automatique.

2. **Réentraînement et audit périodique.** En cas de déploiement opérationnel, le modèle doit être réentraîné annuellement et audité pour détecter toute dérive de performance ou d'équité (*model drift*).
3. **Droit de contestation.** Tout employé doit pouvoir demander une explication de sa classification et contester les conclusions du système auprès d'un interlocuteur humain.
4. **Comité de supervision.** Le déploiement opérationnel du système nécessiterait la constitution d'un comité de supervision incluant des représentants RH, des représentants du personnel et un référent éthique.

2.5 Application au projet HumanForYou sous le cadre européen

En nous plaçant dans le cadre réglementaire européen, notre projet de prédiction de l'attrition doit respecter plusieurs exigences.

Protection des données personnelles

Les données utilisées contiennent des informations sensibles sur les employés : salaire, évaluations de performance, satisfaction, horaires de travail, statut marital. La **pseudonymisation** (identifiants numériques plutôt que noms) est déjà appliquée dans le jeu de données via la clé `EmployeeID`, ce qui constitue une bonne pratique conforme au RGPD.

Risques de biais et de discrimination

Certaines variables du jeu de données — telles que `Gender`, `MaritalStatus`, `Age` ou `Education` — sont des attributs protégés susceptibles d'introduire des biais discriminatoires dans le modèle. Il sera nécessaire de :

- Mesurer l'impact de ces variables sur les prédictions ;
- Évaluer l'équité du modèle selon différentes métriques (parité démographique, égalité des chances, etc.) ;
- Le cas échéant, appliquer des techniques de débiaisage.

Transparence et explicabilité

Conformément aux principes du HLEG et aux exigences de l'AI Act, le modèle doit être **interprétable** : il ne suffit pas de prédire l'attrition, il faut être en mesure d'expliquer *pourquoi* un employé est identifié comme à risque. L'utilisation de techniques d'explicabilité (importance des variables, SHAP, LIME, etc.) sera privilégiée.

Supervision humaine

Les résultats du modèle doivent servir d'**aide à la décision** et non de décision automatique. Toute action RH fondée sur les prédictions (entretien, formation, ajustement salarial) doit impliquer un jugement humain qualifié, conformément à l'article 22 du RGPD.

Finalité et proportionnalité

Le modèle doit être utilisé dans une finalité légitime : **la rétention des talents et l'amélioration des conditions de travail**, et non la surveillance ou la sanction des employés. Cette distinction est fondamentale pour garantir la conformité éthique et juridique du projet.

3 Conclusion

Ce projet a permis de mener une analyse complète du turnover chez HumanForYou, de l’exploration des données à la formulation de recommandations stratégiques, en passant par la construction de modèles prédictifs.

Trois résultats clés se dégagent. Premièrement, la surcharge horaire est le premier facteur d’attrition — un résultat obtenu grâce aux données de badgeage, souvent sous-exploitées. Deuxièmement, le profil type de l’employé à risque est un jeune collaborateur, récemment arrivé, avec un nouveau manager et des déplacements fréquents. Troisièmement, les modèles ensemblistes (forêt aléatoire, gradient boosting) surpassent nettement la régression logistique, confirmant la présence d’interactions non linéaires entre facteurs.

L’ancrage réglementaire dans le cadre européen (RGPD, AI Act) a guidé chaque étape : pseudonymisation des données, conservation des attributs protégés avec analyse de biais, explicabilité via SHAP, et positionnement strict du modèle comme aide à la décision — jamais comme système autonome. Ce cadre offre des garanties de confiance essentielles pour l’acceptabilité du système par les employés.

Limites et perspectives. Le jeu de données est une coupe transversale (2015–2016) ; un suivi longitudinal permettrait de capturer l’évolution des facteurs dans le temps. L’intégration de données qualitatives (entretiens de sortie, verbatims d’enquêtes) enrichirait la compréhension des motifs de départ. Enfin, le déploiement effectif du modèle nécessiterait une **analyse d’impact relative à la protection des données** (AIPD) et la constitution d’un comité de supervision, conformément aux obligations pour les systèmes à haut risque.

Références

- [1] CNIL, *Comprendre le RGPD*, <https://www.cnil.fr/fr/comprendre-le-rgpd>.
- [2] CNIL, *Guide de la sécurité des données personnelles*, édition 2023, https://www.cnil.fr/sites/cnil/files/2023-04/cnil_guide_securite_des_donnees_personnelles-2023.pdf.
- [3] CNIL, *Comment permettre à l'Homme de garder la main ? Rapport sur les enjeux éthiques des algorithmes et de l'intelligence artificielle*, décembre 2017, <https://www.cnil.fr/fr/comment-permettre-lhomme-de-garder-la-main-rapport-sur-les-enjeux-ethiques-des-a>.
- [4] CNIL, *Lignes directrices et recommandations*, <https://www.cnil.fr/en/decisions/lignes-directrices-recommandations-CNIL>.
- [5] Parlement européen et Conseil de l'Union européenne, *Règlement (UE) 2024/1689 établissant des règles harmonisées concernant l'intelligence artificielle (AI Act)*, Journal officiel, 13 juin 2024. Considérant 27, <https://artificialintelligenceact.eu/fr/recital/27/>.
- [6] Groupe d'experts de haut niveau sur l'IA, *Lignes directrices en matière d'éthique pour une IA digne de confiance*, Commission européenne, 2019, https://ec.europa.eu/newsroom/dae/document.cfm?doc_id=60427.
- [7] Villani, C. et al., *Donner un sens à l'intelligence artificielle : pour une stratégie nationale et européenne*, rapport au Premier ministre, mars 2018, <https://www.vie-publique.fr/rapport/37225-donner-un-sens-lintelligence-artificielle-pour-une-strategie-nation>.
- [8] Hub France IA, *Guide pratique IA éthique*, version 2, décembre 2024, https://www.hub-franceia.fr/wp-content/uploads/2024/12/Guide_pratique_IA_ethique_version-2.pdf.
- [9] Centre de politique européenne, *Lignes directrices en matière d'éthique pour l'IA : analyse de la communication COM(2019) 168*, https://www.cep.eu/fileadmin/user_upload/cep.eu/Analysen/COM_2019_168_Ethik_in_KI/CA_COM_2019_168__Lignes_directrices_en_matiere_d_ethique_pour_l_IA.pdf.
- [10] Commission européenne, *Lignes directrices relatives à l'utilisation de l'intelligence artificielle*, 2022, https://teachertaskforce.org/sites/default/files/2023-06/2022_EC_lignes-directrices-utilisation-IA_FR.pdf.
- [11] DARPA, *Explainable Artificial Intelligence (XAI) Program*, <https://www.darpa.mil/research/programs/explainable-artificial-intelligence>.
- [12] Quantmetry (Capgemini), *Intelligence artificielle et éthique : comment définir et mesurer l'équité algorithmique*, <https://www.quantmetry.com/blog/intelligence-artificielle-et-ethique-comment-definir-et-mesurer-lequite-algorithm>.